

Výstupy ŠVP

INF-01a Interpretuji získané výsledky a závěry, vyslovuji předpovědi na základě dat a uvažuji při tom omezení použitých modelů. (Informatika 2, 1/2 · z INF-01)

INF-01c Odhaluji chyby a manipulace v cizích interpretacích a závěrech; fakta, důkazy a argumenty posuzuji bez ohledu na to, zda jsou či nejsou v souladu s mým dosavadním názorem. (Informatika 2, 1/2 · z INF-01)

MAT-19 Umím pracovat se statistickými údaji, porovnávat je a využít je při svém rozhodování. (Matematika 4, 2/2)

Učivo: interpretace dat – kvalita informačního zdroje; chyby a manipulace v interpretacích dat; kritické myšlení a kognitivní zkreslení

Lehké úlohy procvičí rozlišení absolutních a relativních údajů, zdrojů a zkreslení; ve středních odhaluješ manipulaci výpočtem; těžké vyžadují pečlivé zdůvodnění, kdy data tvrzení podporují a kdy ne. Pojmy a vzorce máš v listu Must know. Vyber si, kolik úloh spočítáš; řešení si ukládej do svého portfolia.

Lehké ★☆☆

- Městečko A (10 000 obyvatel) mělo za rok 50 dopravních nehod, město B (200 000 obyvatel) 400 nehod. Titulek: „Ve městě B je osmkrát víc nehod – je tam nebezpečněji.“ Porovnej města správně.
- Internetový průzkum zjistil, že 98 % dotázaných používá internet každý den. Lze z toho usoudit, kolik lidí v Česku používá internet? Co je na vzorku špatně?
- Studie zjistila, že žáci, kteří snídají, mají v průměru lepší známky. Plyne z toho, že snídaně zlepšují známky? Navrhni aspoň dvě skryté proměnné.
- Rozhodni, zda jde o primární, nebo sekundární zdroj: a) tabulky cen potravin na webu Českého statistického úřadu; b) novinový článek o těchto tabulkách; c) vědecký článek s vlastním měřením; d) učebnice fyziky; e) příspěvek politika na sociální síti, který cituje studii.
- Koláčový graf ankety „Jaké sporty děláš?“ má výseče, jejichž procenta dávají dohromady 115 %. Co je špatně? Jaký graf by byl vhodnější?
- Přiřaď kognitivní zkreslení (konfirmační zkreslení, heuristika dostupnosti, gamblerův klam): a) „Po zprávách o letecké havárii se bojím letět, autem jezdím bez obav.“ b) „Čtu jen weby, které potvrzují můj názor.“ c) „Pětkrát za sebou padl rub, teď už musí padnout líc.“

Střední ★★☆☆

- Třída A (20 žáků) má průměrnou známku 1,5, třída B (30 žáků) 2,5. Článek píše: „Průměr ročníku je 2,0.“ Je to pravda? Spočítej správný průměr.
- Firma ukazuje graf „celkový počet prodaných kusů od začátku roku“: 100, 190, 270, 340, 400 (leden až květen). Graf stále stoupá. Rostou prodeje? Převed' data na měsíční prodeje.
- Dítě vyrostlo mezi 5. a 10. rokem ze 110 cm na 140 cm. Podle lineárního modelu urči rychlost růstu a předpověz výšku ve 40 letech. Co je na předpovědi špatně?
- Cena zboží nejprve vzrostla o 25 % a pak klesla o 20 %. Je zpět na původní hodnotě? Jiná akcie klesla o 50 % a pak vzrostla o 50 %. Kolik procent původní hodnoty má?
- Anketa A: 3 z 5 dotázaných chtějí delší přestávky (60 %). Anketa B: 600 z 1 000 (60 %). Odhad nejistoty výsledku je asi $\pm 2 \sqrt{\frac{p(1-p)}{n}}$. Spočítej ji pro obě ankety. Které tvrzení „většina chce delší přestávky“ je podloženo?
- Graf počtu uživatelů aplikace má osu y s hodnotami 1, 10, 100, 1 000, 10 000 ve stejných vzdálenostech (logaritmická osa) a data na něm tvoří přímku. Jak ve skutečnosti počet uživatelů roste? Proč může laik graf špatně pochopit?

Těžké ★★★

- Test na vzácnou nemoc odhalí 99 % nemocných a u 1 % zdravých chybně vyjde pozitivně. Nemoc má 1 člověk z 1 000. Test vyšel pozitivně. Jaká je pravděpodobnost, že je člověk opravdu nemocný? Počítej se 100 000 testovanými.

14. Co program vypíše? Funkce korelace počítá korelační koeficient (1 = dokonalá přímá závislost, 0 = žádná lineární závislost). Znamená silná korelace, že každá hodina učení navíc přinese přesně stejný počet bodů? Co by bylo potřeba k prokázání příčiny?

```
def korelace(x, y):
    n = len(x)
    mx, my = sum(x) / n, sum(y) / n
    sxy = sum((a - mx) * (b - my) for a, b in zip(x, y))
    sxx = sum((a - mx) ** 2 for a in x)
    syy = sum((b - my) ** 2 for b in y)
    return sxy / (sxx * syy) ** 0.5

hodiny = [1, 2, 3, 4, 5]
body = [52, 60, 61, 70, 77]
print(sum(body) / len(body))
print(round(korelace(hodiny, body), 3))
```

15. Škola dala doučování 10 % žáků s nejhorším výsledkem prvního testu. Ve druhém testu se tito žáci v průměru zlepšili. Ředitel tvrdí: „Doučování funguje.“ Proč to z dat neplyne? Jak by měl pokus vypadat?
16. Země A vypustí ročně 10 milionů tun CO₂ a má 1 milion obyvatel, země B vypustí 1 000 milionů tun a má 1,4 miliardy obyvatel. Která země „znečišťuje víc“? Uveď dva různé pohledy a řekni, který údaj by měl titulek uvést.
17. Jedeš na výlet 60 km rychlostí 60 km/h a zpět stejnou cestu rychlostí 40 km/h. Kamarád tvrdí, že průměrná rychlost je 50 km/h. Má pravdu? Jak by to vyšlo, kdybys zpět jel 120 km/h?
18. Titulek zní: „Počet nehod cyklistů se za 10 let zdvojnásobil.“ Sestav aspoň čtyři otázky, které si položíš, než tvrzení uvěříš nebo ho budeš sdílet.

Výsledky ke kontrole

1. přepočet na 1 000 obyvatel: A 5 nehod, B 2 nehody – relativně je bezpečněji v B; absolutní počty velkého a malého města nelze přímo porovnávat
2. nelze – vzorek tvoří jen lidé, kteří jsou na internetu (výběrové zkreslení); lidé bez internetu nemohli odpovédět, vzorek není reprezentativní
3. neplyne – jde o korelaci; skryté proměnné např. pravidelný režim a dostatek spánku, zájem rodičů o dítě, ekonomická situace rodiny; příčinu by ověřil jen pokus s kontrolní skupinou
4. primární: a), c) (vlastní data); sekundární: b), d), e) – přebírají a vykládají cizí data, je dobré dohledat původní zdroj
5. u otázky s více možnými odpověďmi jeden žák volí víc sportů, součet přesahuje 100 % – koláč ale zobrazuje části jednoho celku; vhodnější je sloupcový graf (procento žáků u každého sportu)
6. a) heuristika dostupnosti (živě zapamatovaná událost se zdá častější); b) konfirmační zkreslení; c) gamblerův klam (mince si nepamatuje minulé hody, líc má stále $\frac{1}{2}$)
7. není – třídy jsou různě velké; vážený průměr
$$\frac{20 \cdot 1,5 + 30 \cdot 2,5}{50} = 2,1$$
8. měsíční prodeje: 100, 90, 80, 70, 60 – klesají; kumulativní (součtový) graf roste vždy, když se něco prodá, a pokles zakrývá
9. 6,0 cm za rok; ve 40 letech $140 + 30 \cdot 6 = 320$ cm – nesmysl; model platí jen v rozsahu naměřených dat, růst se v pubertě zastaví (extrapolace)
10. první: $1,25 \cdot 0,8 = 1 \rightarrow$ ano, stejná cena; druhá: $0,5 \cdot 1,5 = 0,75 \rightarrow 75$ %, tj. pokles o 25 %; procenta se počítají pokaždé z jiného základu, nelze je sčítat
11. A: ± 44 procentních bodů (skutečnost může být od 16 % do 100 %); B: $\pm 3,1$ p. b.; podložené je jen B – malý vzorek dává velmi nejistý výsledek
12. přímka na logaritmické ose znamená exponenciální růst – za stejnou dobu se počet vždy násobí stejným číslem (např. $10\times$); laik vidí „rovnoměrný“ růst a netuší, že každý dílek je desetinásobek
13. nemocných 100, pozitivních z nich 99; zdravých 99 900, falešně pozitivních 999; $P = \frac{99}{99 + 999} \doteq 0,090$, tj. asi 9 % – u vzácné nemoci je většina pozitivních výsledků falešných (zanedbání základní četnosti)
14. $64,0 / 0,981$ – průměr 64 bodů, velmi silná korelace; ne – korelace neříká nic o příčině ani o přesné velikosti vlivu, 5 žáků je málo; příčinu prokáže pokus (náhodně rozdělené skupiny s různou dobou učení)
15. nejhorší výsledky jsou zčásti dané smůlou (špatný den), při dalším testu se žáci přiblíží svému průměru i bez doučování (regrese k průměru); je třeba kontrolní skupina podobně slabých žáků bez doučování a porovnat zlepšení obou skupin
16. celkem víc B ($100\times$); na obyvatele A: 10,0 t, B: asi 0,71 t $\rightarrow$ na osobu víc A (asi $14\times$); titulek by měl říct, který ukazatel používá, nejlépe uvést oba
17. nemá: tam 1 h, zpět 1,5 h, průměr $\frac{120}{2,5} = 48$ km/h (déle jedeš pomaleji, pomalejší úsek má větší váhu); se zpáteční rychlostí 120: $\frac{120}{1,5} = 80$ km/h, ne 90
18. např.: Kdo data sbíral a jak (změnila se evidence)? Kolik lidí jezdí na kole dnes a před 10 lety (relativně k počtu cyklistů)? Proč bylo vybráno právě toto období (vyzobávání)? Jde o všechny nehody, nebo jen s úrazem? Kde je původní zdroj a co přesně uvádí?