

Výstupy ŠVP

INF-19b Při využívání digitálních technologií a sociálních sítí si umím chránit své soukromí a poskytovat o sobě pouze ty informace, které chci; v online světě se snažím minimalizovat svou digitální stopu, zejména tam, kde je to potenciálně nebezpečné. (Informatika 4, 2/2 · z INF-19)

Učivo: bezpečné digitální prostředí

Lehké úlohy procvičí pojmy digitální identita, stopa, cookies a metadata; ve středních počítáš, kolik se o tobě dá z dat zjistit; těžké ukazují, proč je skutečná anonymizace těžká a kdo na datech vydělává. Pojmy a vzorce máš v listu Must know. Vyber si, kolik úloh spočítáš; řešení si ukládej do svého portfolia.

Lehké ★☆☆

1. U zprávy v chatu rozliš obsah a metadata: text zprávy; čas odeslání; kdo zprávu poslal a komu; přiložená fotka; poloha, kde byla fotka pořízena; velikost přílohy. Proč jsou metadata cenná, i když neznáš obsah?
2. Které ověření totožnosti je „silné“ (úřad nebo banka ví, že jsi to opravdu ty) a které „slabé“: heslo k e-mailu; občanský průkaz s čipem a čtečkou; bankovní identita; přezdívka na fóru; přihlášení účtem sociální sítě?
3. Na webu zpravy-xy.cz se ukládají cookies z domén zpravy-xy.cz, reklamni-sit.com a analytika.net. Které jsou cookies první strany a které třetích stran? Která firma tě může sledovat na mnoha různých webech a jak?
4. Co bys neměl sdílet veřejně a proč: fotku letenky s čárovým kódem; fotku svého psa; přesnou adresu bydliště; název školy a svůj rozvrh; oblíbenou kapelu?
5. Smazal jsi nevhodný příspěvek 10 minut po zveřejnění. Zmizel úplně? Uveď aspoň tři místa, kde může dál existovat.
6. Přiřaď právo podle GDPR k situaci: právo na přístup, na opravu, na výmaz, na přenositelnost, vznést námitku. a) chceš vědět, jaká data o tobě e-shop má; b) v profilu máš špatné datum narození; c) chceš si přenést seznam skladeb do jiné služby; d) nechceš dostávat cílenou reklamu; e) rušíš účet a chceš, aby data zmizela.

Střední ★★☆☆

7. Předpokládej, že v Česku je asi 3 000 poštovních směrovacích čísel, lidé mají narozeniny v některý z 365 dní, narodili se v jednom z asi 80 ročníků a mají jedno ze 2 pohlaví. Kolik je kombinací PSČ + datum narození + pohlaví? Česko má asi 10,9 milionu obyvatel. Co z toho plyne pro „anonymní“ data?
8. Oblíbené filmy: Anička – Duna, Matrix, Shrek; Bára – Duna, Matrix, Avatar, Interstellar; Cyril – Shrek, Frozen, Coco; Dan – Matrix, Avatar. Doporučovací algoritmus najde uživatele s nejvíc společnými filmy a doporučí jeho filmy, které Anička neviděla. Co doporučí? Proč tak může vzniknout bublina?
9. Elektronický podpis podepisuje otisk (hash) dokumentu. Co program vypíše (tři otisky)? Co se stane s podpisem, když někdo ve smlouvě změní jediný znak?

```
import hashlib

def otisk(text):
    return hashlib.sha256(text.encode()).hexdigest()[:16]

print(otisk("Zaplatím 1000 Kč."))
print(otisk("Zaplatím 9000 Kč."))
print(otisk("Zaplatím 1000 Kč."))
```

10. Telefon ukládá polohu každých 5 minut. Kolik bodů polohy nasbírá za rok? Co všechno se z nich dá vyčíst, i když nejsou spojeny se jménem?
11. Přijde ti žádost o přátelství: účet je 5 dní starý, nemáte žádné společné přátele, profilová fotka vypadá jako z reklamy, po pár zprávách tě prosí o fotky nebo o půjčku. Které znaky ukazují na falešnou identitu? Jak si profil ověříš?
12. Na veřejné Wi-Fi v kavárně otevřeš stránku <https://nemocnice-xy.cz/objednani/kozni>. Co může vidět provozovatel sítě a co ne? Co by viděl, kdyby stránka používala jen http?

13. Tabulka (věk; obec; diagnóza): (23; Brno; chřipka), (27; Brno; angína), (34; Brno; chřipka), (38; Brno; zlomenina), (41; Blansko; chřipka), (45; Blansko; alergie), (52; Blansko; angína), (29; Blansko; chřipka). Data jsou k -anonymní, když každou kombinaci věku a obce má aspoň k lidí. Nahraď věk desetiletím (20–29, 30–39 ...): jaké k vyjde? Jak data upravit, aby bylo $k \geq 3$?
14. Model bubliny: aplikace nabídne téma „hudba“ s pravděpodobností rovnou podílu dosavadních kliknutí na hudbu (na začátku 1 klik hudba, 1 sport) a každá nabídka získá klik. Simuluj 100 nabídek a urči podíl hudby; celé zopakuj 2 000×. V kolika procentech běhů skončí podíl některého tématu nad 80 %?
15. Reklamní síť dostane od inzerentů 5 Kč za 1 000 zobrazení reklamy. Uživatel uvidí 200 reklam denně. Kolik na něm síť vydělá za rok? Kolik při 5 milionech uživatelů? Co platíš za „bezplatnou“ službu?
16. Co program vypíše? Program zpracovává záznam webového serveru (čas, IP adresa, stránka). Co se z výsledku dá odhadnout o návštěvníkovi 10.0.0.5? Proč server takové záznamy vidí vždy, i když nepoužíváš cookies?

```
zaznamy = [("08:01", "10.0.0.5", "/zpravy"), ("08:02", "10.0.0.7", "/sport"),
           ("08:05", "10.0.0.5", "/pocasi"), ("08:09", "10.0.0.5", "/zpravy/volby"),
           ("08:11", "10.0.0.9", "/zpravy"), ("08:15", "10.0.0.7", "/sport/hokej")]
navstevy = {}
for cas, ip, stranka in zaznamy:
    if ip not in navstevy:
        navstevy[ip] = []
    navstevy[ip].append(stranka)
for ip in navstevy:
    print(ip, len(navstevy[ip]), navstevy[ip])
```

17. Firma „anonymizovala“ data tak, že jméno nahradila jeho otiskem (prvních 8 znaků SHA-256). V datech najdeš otisk ze zdrojového kódu programu. Co program udělá a vypíše? Proč je taková pseudonymizace slabá?

```
import hashlib

def pseudonym(jmeno):
    return hashlib.sha256(jmeno.encode()).hexdigest()[:8]

hledany = "893bf827"
for jmeno in ["Jan", "Petr", "Eva", "Tereza", "Jakub"]:
    if pseudonym(jmeno) == hledany:
        print("Nalezeno:", jmeno)
```

18. Po letech chceš, aby se po zadání tvého jména ve vyhledávači neukazoval starý článek. Vyhledávač na tvou žádost odkaz odstraní. Zmizí tím článek? Kdo by musel jednat, aby zmizel úplně, a proč se to nemusí podařit?

1. obsah: text, fotka; metadata: čas, odesílatel a příjemce, poloha fotky, velikost přílohy; z metadata se dá vyčíst, s kým se stýkáš, kdy a kde býváš – bez čtení zpráv
2. silné: občanka s čipem, bankovní identita (totožnost byla ověřena osobně, přihlášení chrání víc faktorů); slabé: heslo k e-mailu, přezdívka, účet sociální sítě (kdokoli ho může založit pod cizím jménem)
3. první strany: zpravy-xy.cz; třetích stran: reklamni-sit.com, analytika.net; reklamní síť – její skript a cookie jsou na tisících webů, takže pozná tvůj prohlížeč všude, kde je zapojena
4. nesdílet: letenku (z kódu lze zjistit rezervaci a změnit ji), adresu, školu s rozvrhem (kdo tě hledá, ví kdy a kde jsi); pes a kapela jsou většinou v pořádku (pozor na jméno psa jako odpověď na bezpečnostní otázku)
5. nemusí – mohl ho někdo zachytit snímkem obrazovky, sdílet nebo stáhnout, uložit ho mohl internetový archiv nebo vyhledávač a služba ho může mít ještě v zálohách
6. a) přístup; b) oprava; c) přenositelnost; d) námitka (proti zpracování pro přímý marketing); e) výmaz („právo být zapomenut“)
7. $3000 \cdot 365 \cdot 80 \cdot 2 = 175\,200\,000$ kombinací, na jednu připadá v průměru asi 0,06 člověka – většina lidí je podle těchto tří údajů jednoznačně určena; odstranit jméno nestačí
8. nejpodobnější je Bára (2 společné filmy) → doporučí Avatar a Interstellar; algoritmus nabízí stále podobné věci jako lidé „jako ty“, jiné žánry (Frozen, Coco) se ke tobě nedostanou
9. 1. a 3. otisk jsou stejné (95cee6c331e0b9f3), 2. je úplně jiný (873641f31e2e09b8); změna jediného znaku změní otisk, podpis přestane sedět a změna se pozná
10. $12 \cdot 24 \cdot 365 = 105\,120$ bodů; kde bydlíš (noci), kam chodíš do školy nebo práce, koho navštěvuješ, kdy sportuješ, jestli chodíš k lékaři – z bydliště a školy lze snadno určit, kdo jsi
11. nový účet, žádné vazby, cizí (fotobankové) foto, rychlý přechod k žádostem o citlivé věci nebo peníze; ověření: zpětné vyhledání obrázku, dotaz přes jiný kanál (osobně, telefonem), nic neposílat; podezřelý účet nahlásit
12. u https vidíš, že se připojuješ k doméně nemocnice-xy.cz (a kdy a kolik dat), ale ne cestu /objednani/kozni ani obsah formuláře; u http by viděl celou adresu i vše, co vyplníš
13. po desetiletích má např. kombinace (50–59; Blansko) i (20–29; Blansko) jen 1 člověka → $k = 1$, člověk je dohledatelný; při dvacetiletích zůstane (20–39; Blansko) s 1 člověkem; $k \geq 3$ dá až vynechání věku (obec: Brno 4, Blansko 4 → $k = 4$) nebo vyřazení výjimečných záznamů – cenou je ztráta informace
14. podíl nekonverguje k 50 % – co získá náskok, dostává víc nabídek; v simulaci skončí asi 39 % běhů s podílem nad 80 % nebo pod 20 % (teorie: podíl je rovnoměrně rozdělený, tj. asi 40 %); náhodné rané kliky rozhodnou, co uvidíš
15. $200 \cdot 365 = 73\,000$ zobrazení → 365 Kč za rok; při 5 milionech uživatelů asi 1,8 miliardy Kč; platíš pozorností a daty o sobě – čím víc o tobě síť ví, tím draž reklamu prodá
16. 10.0.0.5 3 ["/zpravy", "/pocasi", "/zpravy/volby"] / 10.0.0.7 2 ["/sport", "/sport/hokej"] / 10.0.0.9 1 ["/zpravy"]; návštěvník 10.0.0.5 čte zprávy o volbách a počasí (zájmy, čas aktivity); IP adresa a požadovaná stránka jsou součástí každého požadavku – server je vidí bez cookies
17. zkouší otisky běžných jmen, dokud nenajde shodu → vypíše Nalezeno: Tereza; jmen je málo (desítky tisíc), útočník je všechna zahašuje a porovná (slovníkový útok) – otisk bez tajné soli jméno neskryje
18. nezmizí – vyhledávač jen přestane odkaz zobrazovat (u hledání tvého jména); článek je dál na webu vydavatele, ten by ho musel smazat; nemusí souhlasit (svoboda tisku, veřejný zájem) a kopie mohou být v archivech a na jiných webech