


Lineární klasifikátor rozdělí rovinu přímkou na dvě poloroviny, každá patří jedné třídě. Učit se znamená hledat koeficienty přímky z příkladů; kvalitu ověřujeme na datech, která model neviděl.

Zapamatuj si

- Klasifikátor $f(x, y) = ax + by + c$: $f > 0 \rightarrow$ třída +1, $f < 0 \rightarrow$ třída -1; hranice $f = 0$.
- $\vec{n} = (a; b)$ míří na kladnou stranu; změna c přímku posune, změna a, b ji natočí.
- Jistota rozhodnutí = vzdálenost od hranice
$$d = \frac{|ax_0 + by_0 + c|}{\sqrt{a^2 + b^2}}$$


- Perceptron po chybě na $[x_0; y_0]$ se třídou t : $a \leftarrow a + tx_0$, $b \leftarrow b + ty_0$, $c \leftarrow c + t$.
- Přesnost = správně : celkem, měřená na testovacích datech; velký rozdíl proti trénovacím = přeučení.
- Co přímka neoddělí (XOR), zvládne víc neuronů ve vrstvách – neuronová síť.

Lineární klasifikátor




Body nad hranicí mají $f > 0$, pod ní $f < 0$. Nový bod $[2; 2]$ leží blízko hranice – rozhodnutí je nejisté.

Perceptron se učí: přímka se posouvá




Start $a = 1$, $b = 0$, $c = -2$: P i Q jsou na špatné straně. Po dvou úpravách leží oba body správně.

Přeučení



Model A zná trénovací data nazpaměť i se šumem, na nových datech selhává. Nasaďme model B.


Perceptron – model neuronu



příklad: $f = 3 \cdot 2 + 2 \cdot 2 - 12 = -2 \rightarrow$ výstup -1

Vstupy se vynásobí vahami a sečtou; znaménko součtu určí třídu. Váhy a, b, c jsou koeficienty přímky.



Trénování × testování



	skutečnost		
	je to spam	je běžný	
model: spam	18 správně	3 planý poplach	přesnost 45 : 50 = 90 %
model: běžný	2 přehlédnutí	27 správně	

Filtr spamu na 50 testovacích e-mailech: 45 správně, 3 plané poplavy, 2 přehlédnuté spamy.

Když přímka nestačí: neuronová síť



Skrytá vrstva složí několik přímek do složitější hranice; hluboké sítě mají vrstev mnoho.