

Výstupy ŠVP**INF-18** Identifikuji a řeším problémy a výzvy vznikající při práci s digitálními zařízeními a poradím s nimi druhým. (*Informatika 5, 3/1*)**MAT-32** V úlohách početní geometrie aplikuji funkční vztahy, trigonometrii a úpravy výrazů, pracuji s proměnnými a iracionálními čísly. (*Matematika 5, 3/1*)**FYZ-10** Využívám stavovou rovnici ideálního plynu stálé hmotnosti při předvídání stavových změn plynu. (*Fyzika 3, 3/1*)**Učivo:** umělá inteligence – princip strojového učení; aplikace umělé inteligence; limity, přínosy a rizika umělé inteligence**Základní pojmy****Model** – Zjednodušený popis závislosti – funkce s parametry, která ze vstupu (např. teploty) předpoví výstup (např. tlak).**Fyzikální model** – Odvozený ze zákonů a předpokladů (ideální plyn: $pV = nRT$); parametry mají fyzikální význam a model platí i mimo naměřený rozsah, dokud platí předpoklady.**Datový (empirický) model** – Tvar funkce zvolíme a parametry dopočítá počítač z dat – tak pracuje strojové učení; popisuje hlavně to, co v datech viděl.**Regrese** – Hledání funkce, která nejlépe odpovídá naměřeným bodům a předpovídá číslo (na rozdíl od klasifikace do tříd).**Reziduum** e_i – Odchylka naměřené hodnoty od modelu: $e_i = y_i - \hat{y}_i$.**Metoda nejmenších čtverců** – Parametry volíme tak, aby součet čtverců reziduí $\sum e_i^2$ byl co nejmenší.**RMSE a R^2** – RMSE = typická velikost chyby v jednotkách y ; R^2 = podíl rozptylu dat, který model vysvětlí ($R^2 = 1$: body leží přesně na křivce).**Trénovací × testovací data** – Na trénovacích model hledá parametry; testovací odložíme předem a jen na nich měříme, jak model předpovídá nové hodnoty.**Přeučení** – Model s příliš mnoha parametry se naučí i šum měření: na trénovacích datech skoro bez chyby, na nových datech selhává.**Interpolace × extrapolace** – Předpověď uvnitř × mimo rozsah naměřených dat; extrapolace je spolehlivá jen s fyzikálním modelem.**Linearizace** – Úprava vztahu na přímku: $p = \frac{C}{V}$ je přímka v osách $\frac{1}{V}$ a p , mocninný vztah je přímka v osách $\ln V$ a $\ln p$.**Vzorce a vztahy** $\hat{y} = ax + b$ lineární model; a směrnice, b úsek na ose y $e_i = y_i - \hat{y}_i$ reziduum (odchylka bodu od modelu)

$$a = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

směrnice podle metody nejmenších čtverců

 $b = \bar{y} - a\bar{x}$ přímka vždy prochází bodem $[\bar{x}; \bar{y}]$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum e_i^2}$$

střední kvadratická chyba

$$R^2 = 1 - \frac{\sum e_i^2}{\sum (y_i - \bar{y})^2}$$

koeficient determinace

$$\frac{p_1 V_1}{T_1} = \frac{p_2 V_2}{T_2}$$

stavová rovnice plynu stálé hmotnosti (viz H11); T v kelvinech

$$p = at + b, \quad t_0 = -\frac{b}{a}$$

izochorický děj s t ve $^{\circ}\text{C}$; t_0 = odhad absolutní nuly (model: $a = \frac{p_0}{273,15 \text{ K}}$)

$$\ln p = \ln C + k \ln V$$

mocninný model $p = CV^k$
zlinearizovaný logaritmem; pro izotermický děj $k = -1$

Poučky a postupy

- Postup modelování: data → graf → tvar modelu (napoví fyzika) → parametry z trénovacích dat → chyba na testovacích datech → význam parametrů a meze platnosti.
- Vždy se podívej na graf reziduí: náhodný rozptyl kolem nuly = šum měření; oblouk nebo trend = špatně zvolený tvar modelu.
- Víc parametrů neznamená lepší model: polynom stupně $n - 1$ projde všemi n body ($R^2 = 1$), ale mezi body a mimo ně divoce kmitá.
- V Pythonu: $a, b = \text{np.polyfit}(x, y, 1)$ – koeficienty jdou od nejvyšší mocniny; hodnotu modelu spočítá $\text{np.polyval}(k, x)$.
- Kód od Gemini ověř: spusť ho na datech se známým výsledkem, zkontroluj jednotky a převody ($^{\circ}\text{C} \rightarrow \text{K}$, $\text{l} \rightarrow \text{m}^3$), porovnej s odhadem ze dvou bodů a s grafem.
- Do Gemini vkládej jen data z měření, žádné osobní údaje; v portfoliu uveď, s čím ti AI pomohla a jak jsi výsledek ověřil(a).

Pozor na

- R^2 blízko 1 ještě nedokazuje správný model – na krátkém úseku vypadá přímka dobře i u zakřivené závislosti. Rozhodují rezidua a testovací data.
- Testovací data nesmí vstoupit do výpočtu parametrů – jinak hodnotíš model na tom, co už viděl.
- Ve stavové rovnici a v poměrech teplot vždy kelviny; v přímce $p = at + b$ smí být t ve $^{\circ}\text{C}$, absolutní nula je pak $t_0 = -\frac{b}{a}$, ne $-\frac{a}{b}$.
- Korelace není příčina: datový model neřekne proč – vysvětlení dává až fyzikální model.

Vzorový příklad

Vzduch v uzavřené láhvi ohříváme ve vodní lázni: t ($^{\circ}\text{C}$) 0, 20, 40, 60, 80; p (kPa) 100,1; 107,2; 114,8; 121,9; 129,3. Najdi regresní přímku, odhadni absolutní nulu a porovnej s fyzikálním modelem.

1. Průměry: $\bar{t} = 40^{\circ}\text{C}$, $\bar{p} = 114,66$ kPa;
 $\sum (t_i - \bar{t})^2 = 4\,000$, $\sum (t_i - \bar{t})(p_i - \bar{p}) = 1\,462$.
2. $a = \frac{1\,462}{4\,000} \doteq 0,3655$ kPa/ $^{\circ}\text{C}$,
 $b = 114,66 - 0,3655 \cdot 40 \doteq 100,04$ kPa.
3. Rezidua 0,06; -0,15; 0,14; -0,07; 0,02 kPa – náhodná, bez trendu; $R^2 \doteq 0,9999$.
4. Absolutní nula: $t_0 = -\frac{b}{a} = -\frac{100,04}{0,3655} \doteq -273,7^{\circ}\text{C}$
(tabulka: $-273,15^{\circ}\text{C}$, odchylka 0,2 %).
5. Fyzikální model $p = p_0 \frac{T}{T_0}$ dává směrnici
 $\frac{100,1}{273,15} \doteq 0,3665$ kPa/ $^{\circ}\text{C}$ – data s ním souhlasí;
datový model tu jen „znovuobjevil“ Charlesův zákon.