

Výstupy ŠVP

INF-10 Rozpoznám informační toky v systémech; analyzuji a hodnotím informační systémy z různých hledisek; zvažuji i nepřímé a nezamýšlené dopady informačního systému na různé skupiny. (*Informatika 6, 3/2*)

Učivo: hromadné zpracování dat – velká data – zdroje, metody zpracování, využití

Lehké úlohy procvičí jednotky, dostupnost a druhy dat, střední počítají s velkými objemy a anonymizací, těžké propojují velká data s pravděpodobností, energií a hodnocením systémů. Pojmy a vzorce máš v listu Must know. Vyber si, kolik úloh spočítáš; řešení si ukládej do svého portfolio.

Lehké ★☆☆

- Seřaď od nejmenší: 0,002 PB; 1 500 GB; 3 TB; $2 \cdot 10^{12}$ B. Všechny hodnoty převed' na TB.
- Chytrý elektroměr ve 100 000 domácnostech posílá každých 15 minut záznam o velikosti 50 B. Kolik dat vznikne za den? Použij $V = n \cdot f \cdot s \cdot t$.
- Dávkové, nebo průběžné (proudové) zpracování dat? (a) měsíční vyúčtování elektřiny; (b) odhalení podvodné platby kartou ještě během transakce; (c) noční přepočítání statistik prodeje e-shopu; (d) navigace, která reaguje na právě vzniklou zácpu; (e) roční analýza dopravních nehod.
- Cloudová služba byla za rok (8 760 h) mimo provoz celkem 26 hodin. Jaká byla její dostupnost? Splnil poskytovatel slib 99,9 %?
- Který údaj je osobní údaj (lze podle něj přímo nebo nepřímo určit konkrétního člověka)? (a) IP adresa domácího připojení; (b) průměrná teplota v Brně v lednu; (c) poloha telefonu konkrétního člověka; (d) počet návštěvníků ZOO za den; (e) fotografie obličeje; (f) číslo pojištění.
- Jak dlouho trvá přenos zálohy 500 GB linkou 1 Gb/s? Použij $t = \frac{8V}{r}$.

Střední ★★☆☆

- Meteorologický radar vytvoří každých 5 minut snímek o velikosti 12 MB. Kolik dat vznikne za rok? Na kolik let vystačí úložiště 20 TB?
- Analýza 60 TB dat: jeden server zpracuje 200 MB/s. Jak dlouho by analýza trvala na jednom serveru? Kolik serverů je potřeba, aby trvala nejvýš 2 hodiny, když se data dají rovnoměrně rozdělit?
- Zdravotní data „bez jmen“ obsahují PSČ, rok narození a pohlaví. Kolik lidí z tabulky jde jednoznačně určit, když útočník zná tyto tři údaje o svém sousedovi? Co se změní, když se PSČ vynechá? A když se vynechá i rok narození?

PSČ	rok	pohlaví	diagnóza
602 00	2008	Ž	astma
602 00	2008	Ž	alergie
602 00	2009	M	zlomenina
602 00	2009	M	angína
612 00	2008	M	astma
612 00	2010	Ž	cukrovka
612 00	2010	Ž	alergie
615 00	2009	Ž	astma

- E-shop vybírá hosting: A slibuje dostupnost 99,5 % za 400 Kč měsíčně, B 99,95 % za 900 Kč měsíčně. Hodina výpadku stojí e-shop asi 2 000 Kč ušlého zisku. Který hosting se za rok vyplatí víc?
- Doporučovací algoritmus videí nabízí hlavně to, co uživatel už sledoval. Vysvětlí, jak vzniká „informační bublina“, jaká data k tomu algoritmus používá a jaké to má dopady. Navrhni dvě věci, které může udělat uživatel, a jednu, kterou může udělat provozovatel.
- Z 50 milionů příspěvků na sociální síti se náhodně vybralo 10 000 a ručně se ohodnotily; 1 800 z nich bylo negativních. Odhadni podíl a počet negativních příspěvků v celé síti a přesnost odhadu podle vzorce

$$p \pm 1,96 \sqrt{\frac{p(1-p)}{n}} \quad (\text{vazba na H27}). \text{ Proč stačí zpracovat jen vzorek?}$$

13. Program zpracuje záznam (log) webového serveru. Co vypíše? Záznamů je ve skutečnosti 2 miliardy denně na 100 serverech – která část výpočtu může běžet na každém serveru zvlášť (map) a jak se výsledky sloučí (reduce)?

```
logy = ["08:01 200", "08:15 404", "08:47 200", "09:02 500",
        "09:10 200", "09:31 200", "09:58 503", "10:05 200"]
za_hodinu = {}
chyby = 0
for z in logy:
    cas, kod = z.split()
    h = cas[:2]
    za_hodinu[h] = za_hodinu.get(h, 0) + 1
    if kod.startswith("5"):
        chyby += 1
print(za_hodinu)
print(chyby, round(100 * chyby / len(logy), 1))
```

14. Firma „anonymizovala“ databázi zákazníků tak, že e-maily nahradila jejich otiskem (hashem). Útočník má seznam 10 milionů uniklých e-mailů a jeho počítač spočítá miliardu hashů za sekundu. Za jak dlouho zjistí, komu patří záznamy? Proč jde jen o pseudonymizaci a jak by šlo data chránit lépe?
15. Fyzika × data: Datové centrum odebírá ze sítě trvale 2 MW. Ukazatel PUE (celková spotřeba : spotřeba počítačů) je 1,5. Kolik MWh spotřebuje za rok, kolik z toho připadá na samotné servery a kolik na chlazení a ostatní provoz? Kolika domácnostem se spotřebou 2,5 MWh ročně to odpovídá?
16. Škola vybírá mezi dvěma školními IS. Hodnocení 1–5 v kritériích bezpečnost, soukromí, dostupnost, cena: A (4; 3; 5; 4), B (5; 5; 3; 2). Váhy jsou 0,4; 0,3; 0,2; 0,1. Který IS vyjde lépe? Jak se výsledek změní, když se váhy bezpečnosti a dostupnosti prohodí? Co z toho plyne pro rozhodování?
17. Paradox falešných poplachů: Algoritmus hledá podvodné platby. Podvodem je 1 z 10 000 plateb; algoritmus zachytí 99 % podvodů a chybně označí 1 % poctivých plateb. Z 10 milionů plateb: kolik jich označí a jaká část označených je skutečně podvod? Co to znamená pro plošné sledování lidí pomocí velkých dat?
18. Město chce na vjezdech do centra instalovat kamery, které čtou registrační značky aut, aby mohlo vybírat poplatek za vjezd a sledovat dopravu. Zhodnot' návrh z hledisek přínos, bezpečnost dat (CIA), soukromí a dopady na různé skupiny a navrhní pravidla provozu (účel, doba uchování, přístup, kontrola).

Výsledky ke kontrole

- 1 500 GB = 1,5 TB < 0,002 PB = 2 TB = $2 \cdot 10^{12}$ B < 3 TB.
- $f = 96$ záznamů za den;
 $V = 100\,000 \cdot 96 \cdot 50 \text{ B} = 480\,000\,000 \text{ B} = 480 \text{ MB}$
- dávkové: a, c, e (data se nasbírají a zpracují najednou); průběžné: b, d (výsledek je potřeba během sekund).
- $A = \frac{8\,760 - 26}{8\,760} \cdot 100 \% \approx 99,70 \%$ – nesplnil; 99,9 % připouští jen 8,76 h výpadku.
- osobní údaje: a, c, e, f; nejsou: b, d (souhrnná data bez vazby na osobu).
- $t = \frac{8 \cdot 500 \cdot 10^9}{10^9} = 4\,000 \text{ s} \approx 1 \text{ h } 7 \text{ min}$
- 105 120 snímků ročně; $V = 105\,120 \cdot 12 \text{ MB} \approx 1,26 \text{ TB}$;
20: $1,26 \approx 15,9$ roku.
- $\frac{60 \cdot 10^{12}}{200 \cdot 10^6} = 300\,000 \text{ s} \approx 83,3 \text{ h}$; $\lceil 83,3 : 2 \rceil = 42$ serverů (v praxi víc – rozdělení a slučování výsledků také stojí čas).
- s PSČ, rokem a pohlavím jsou jedineční 2 lidé (612 00 2008 M, 615 00 2009 Ž) – útočník zjistí jejich diagnózu; bez PSČ stále 2 (2008 M, 2009 Ž); bez PSČ i roku nikdo – ale data pak skoro nic neřeknou. Anonymizace je vždy kompromis mezi ochranou a užitečností.
- A: výpadek 43,8 h $\rightarrow 87\,600 + 4\,800 = 92\,400 \text{ Kč}$; B: 4,38 h $\rightarrow 8\,760 + 10\,800 = 19\,560 \text{ Kč}$ – vyplatí se B, i když je dražší.
- Algoritmus z dat o sledování (co, jak dlouho, lajky, přeskocení, podobní uživatelé) předpovídá, co udrží pozornost, a nabízí podobný obsah $\rightarrow$ uživatel vidí stále užší výběr názorů. Dopady: zkreslený obraz světa, polarizace, snadnější šíření dezinformací. Uživatel: aktivně hledat jiné zdroje, mazat historii nebo vypnout personalizaci. Provozovatel: nabízet rozmanitý obsah, vysvětlit, proč je video doporučeno.
- $p = 0,18 \pm 0,0075$, tj. 17,25 až 18,75 %; asi 9 milionů příspěvků (přibližně 8,62 až 9,38 milionu); přesnost závisí na velikosti náhodného vzorku, ne na velikosti celku.
- Výstup: {'08': 3, '09': 4, '10': 1} / 2 25.0 – každý server spočítá svůj slovník počtů za hodinu a svůj počet chyb (map); výsledky se sečtou po klíčích (hodinách) a chyby dohromady (reduce), podíl se počítá až z celkových součtů.
- $10^7 : 10^9 = 0,01 \text{ s}$ – stačí spočítat hash každého e-mailu ze seznamu a porovnat. Hash je pořad jednoznačný identifikátor osoby (pseudonymizace, stále osobní údaj). Lépe: hash s tajným klíčem uloženým jinde, nebo identifikátor úplně odstranit a publikovat jen souhrny.
- $2 \text{ MW} \cdot 8\,760 \text{ h} = 17\,520 \text{ MWh}$; servery $\frac{17\,520}{1,5} = 11\,680 \text{ MWh}$, ostatní 5 840 MWh; asi 7 008 domácností.
- A: $0,4 \cdot 4 + 0,3 \cdot 3 + 0,2 \cdot 5 + 0,1 \cdot 4 = 3,9$, B: $4,3 \rightarrow$ B; po prohození A 4,1, B 3,9 $\rightarrow$ A. Výsledek závisí na vahách – musí je předem a zdůvodněně stanovit ti, koho se systém týká.
- podvodů 1 000, zachyceno 990; planých poplachů $0,01 \cdot 9\,999\,000 = 99\,990$; označeno 100 980, z toho podvod jen 0,98 %. U vzácných jevů převáží plané poplachy – plošné „hledání podezřelých“ zasáhne hlavně nevinné.
- Přínos: méně aut v centru, data o dopravě. Bezpečnost: únik databáze pohybů (důvěrnost), podvržené záznamy (integrita), výpadek kamer = výpadek výběru (dostupnost). Soukromí: z průjezdů lze sestavit pohyb konkrétních lidí. Skupiny: obyvatelé centra, řemeslníci, lidé s omezenou pohyblivostí (výjimky). Pravidla: data jen k výběru poplatku, po zaplacení smazat (nebo do několika dnů), statistiky jen anonymně, přístup jen pověřených osob se záznamem, nezávislá kontrola a zveřejněná pravidla.