

Výstupy ŠVP

INF-10 Rozpoznám informační toky v systémech; analyzuji a hodnotím informační systémy z různých hledisek; zvažuji i nepřímé a nezamýšlené dopady informačního systému na různé skupiny. (Informatika 6, 3/2)

Učivo: hromadné zpracování dat – velká data – zdroje, metody zpracování, využití

Základní pojmy

Velká data (big data) – Data tak objemná, rychle přibývající nebo různorodá, že je běžné nástroje (tabulka, jeden server) v rozumném čase nezpracují.

5V – objem (volume), rychlost (velocity), rozmanitost (variety), věrohodnost (veracity), hodnota (value).

Strukturovaná × nestrukturovaná data – Tabulky s pevnými sloupci (platby, měření) × text, obrázky, video, zvuk; nestrukturovaných dat je většina.

Zdroje velkých dat – Senzory a internet věcí, transakce (platby, jízdenky), mobilní sítě a GPS, sociální sítě, záznamy (logy) serverů, vědecká měření.

Distribuované zpracování – Data i výpočet se rozdělí na mnoho počítačů a dílčí výsledky se sloučí (princip MapReduce).

Metody analýzy – Statistika a vizualizace, hledání vzorů a anomálií, strojové učení (H19), rozpoznávání textu a obrazu.

Anonymizace × pseudonymizace – Anonymizace nevratně odstraní vazbu na osobu; pseudonymizace nahradí identitu kódem – s klíčem jde vazbu obnovit, stále jde o osobní údaj.

Digitální stopa – Aktivní (co sám zveřejním) a pasivní (co se o mně zaznamená – poloha, historie, metadata); viz INF-19.

Triáda CIA – Důvěrnost (confidentiality), integrita (integrity), dostupnost (availability) – základ hodnocení bezpečnosti IS.

Dostupnost × přístupnost – Dostupnost: systém funguje, když ho potřebujeme (% doby provozu); přístupnost: mohou ho používat i lidé s postižením či bez pokročilých dovedností.

Vzorce a vztahy

$$1 \text{ PB} = 10^3 \text{ TB} = 10^6 \text{ GB} = 10^{15} \text{ B}$$

desítkové předpony k, M, G, T, P; 1 B = 8 b

$$V = n \cdot f \cdot s \cdot t$$

objem dat: počet zdrojů · četnost záznamů · velikost záznamu · doba

$$t = \frac{8V}{r}$$

doba přenosu: V v bajtech, rychlost linky r v bitech za sekundu

$$A = \frac{t_{\text{provoz}}}{t_{\text{celk}}} \cdot 100 \%$$

dostupnost IS

$$t_{\text{výpadek}} = (1 - A) \cdot t_{\text{celk}}$$

povolený výpadek; rok má 8 760 h

Dostupnost a povolený výpadek za rok

Dostupnost	99 %	99,9 %	99,99 %	99,999 %
Výpadek za rok	3,65 dne	8,76 h	52,6 min	5,3 min

Poučky a postupy

- Hodnot' IS z více hledisek: účel a přínos – bezpečnost (CIA) – soukromí – dostupnost a přístupnost – použitelnost – náklady – dopady na různé skupiny.
- Soukromí: sbírej jen data nutná k účelu (minimalizace), uchovávej je jen po nezbytnou dobu, informuj lidi a dej jim kontrolu nad jejich daty (GDPR).
- U velkých dat začni otázkou, ne daty; ověř věrohodnost zdroje a to, zda data reprezentují všechny skupiny.
- Korelace v datech není příčina; model naučený na zkreslených datech zkreslení převeze (H19).
- Odhad objemu: počet zdrojů · četnost · velikost · čas, pak převed' jednotky (1 B = 8 b).
- Nezamýšlené dopady velkých dat: sledování a profilování, znevýhodnění skupin, závislost na jednom poskytovateli, ztráta anonymity spojením více zdrojů.

Pozor na

- Bajt ≠ bit: 100 Mb/s je jen 12,5 MB/s.
- Smazat jméno nestačí: PSČ, datum narození a pohlaví často člověka jednoznačně určí.
- Dostupnost 99 % zní dobře, ale znamená skoro 4 dny výpadku ročně.
- Víc dat neznamená lepší závěr: chybná nebo nereprezentativní data dávají přesvědčivě špatné výsledky.

Vzorový příklad

Město má 2 000 dopravních senzorů, každý posílá 200 B každých 10 s. Kolik dat vznikne za den a za rok? Jak dlouho by trval přenos ročních dat linkou 100 Mb/s?

- Záznamů za den na senzor: $\frac{86\,400}{10} = 8\,640$.
- Za den:
 $V = 2\,000 \cdot 8\,640 \cdot 200 \text{ B} \approx 3,46 \cdot 10^9 \text{ B} \approx 3,5 \text{ GB}$.
- Za rok: $3,46 \text{ GB} \cdot 365 \approx 1,26 \text{ TB}$.
- Přenos: $t = \frac{8 \cdot 1,26 \cdot 10^{12}}{10^8} \text{ s} \approx 1,0 \cdot 10^5 \text{ s} \approx 28 \text{ h}$.
- Závěr: jeden záznam je malý, ale objem a rychlost přibývání vyžadují databázi a automatické zpracování.