

Výstupy ŠVP

INF-10 Rozpoznám informační toky v systémech; analyzuji a hodnotím informační systémy z různých hledisek; zvažuji i nepřímé a nezamýšlené dopady informačního systému na různé skupiny. (Informatika 6, 3/2)

Učivo: hromadné zpracování dat – velká data – zdroje, metody zpracování, využití

Připomenutí

$$1 \text{ PB} = 10^3 \text{ TB} = 10^6 \text{ GB} = 10^{15} \text{ B}$$

$$V = n \cdot f \cdot s \cdot t$$

$$t = \frac{8V}{r}$$

$$A = \frac{t_{\text{provoz}}}{t_{\text{celk}}} \cdot 100 \%$$

$$t_{\text{výpadek}} = (1 - A) \cdot t_{\text{celk}}$$

Velká data – zdroje, metody zpracování a využití – a hodnocení informačních systémů z hlediska bezpečnosti, soukromí a dostupnosti. U výpočtů piš jednotky a pozor na bity a bajty. Podrobnosti najdeš v listu Must know.

A. Rozcvička

- Rozděl na strukturovaná a nestrukturovaná data: a) tabulka plateb kartou; b) fotky na sociální síti; c) teplota ze senzoru každou minutu; d) e-mail; e) poloha autobusů z GPS; f) hlasové zprávy. ★☆☆
- Přiřaď k popisu jedno z 5V: a) každou sekundu přijde 50 000 plateb; b) data obsahují texty, obrázky i měření; c) archiv má 40 PB; d) část senzorů posílá chybné hodnoty; e) z dat lze zlepšit jízdní řády. ★☆☆
- Převeď: 2,5 PB na TB a na GB; 100 Mb/s na MB/s. Kolik filmů po 4 GB se vejde na 1 TB? ★☆☆
- Poskytovatel cloudové služby slibuje dostupnost 99,95 %. Kolik hodin výpadku za rok tím připouští? ★☆☆
- Rozhodni, zda jde o anonymizaci, pseudonymizaci, nebo nedostatečnou úpravu: a) jména žáků nahrazena kódy Z-0457, převodní tabulku má škola; b) z dat o jízdách se zveřejňuje jen počet cestujících na zastávce za hodinu; c) jména smazána, datum narození nahrazeno rokem, ale PSČ zůstalo. ★☆☆
- Rozliš aktivní a pasivní digitální stopu: a) příspěvek na sociální síti; b) poloha mobilu v síti operátora; c) recenze v e-shopu; d) průchod turniketem na čip; e) historie vyhledávání; f) fotka, na které tě označil kamarád. ★☆☆
- Tři servery spočítaly výskyt slov ve své části příspěvků: S1: vlak 120, bus 80; S2: vlak 95, kolo 40; S3: bus 60, kolo 55, vlak 30. Jaký je celkový výsledek? Proč je výhodné práci takto rozdělit? ★☆☆
- Kterou složku triády CIA incident narušuje? a) únik hesel z e-shopu; b) žák změnil v systému svou známku; c) přetěžovací útok (DDoS) vyřadí web; d) omylem smazaná data bez zálohy; e) zaměstnanec bez důvodu nahlíží do dat sousedů. ★☆☆

B. Slovní úlohy

- Mobilní operátor ukládá o každém z 5 milionů telefonů záznam o poloze (300 B) každých 5 minut. Kolik dat vznikne za den a za rok? ★☆☆
- Jak dlouho trvá přenos 1 TB linkou 100 Mb/s? Kurýr doveze disk s 20 TB za 3 hodiny – jaké „přenosové rychlosti“ to odpovídá? ★☆☆
- Školní IS má ve školním roce (září–červen, 304 dní) zaručenou dostupnost 99,5 %. Kolik hodin výpadku to připouští? Proč nezáleží jen na počtu hodin, ale i na tom, kdy výpadek nastane? ★☆☆
- Navazuje na H41: Zhodnoť eRecept z hledisek bezpečnost (CIA), soukromí, dostupnost a přístupnost. Ke každému hledisku uveď jednu hrozbu nebo slabinu a jedno opatření. ★☆☆
- Najdi přínos, poškozenou skupinu a opatření: a) navigace podle dat o dopravě posílá auta přes klidné obytné ulice; b) pojišťovna nabízí slevu za data z fitness náramku; c) firma třídí životopisy algoritmem naučeným na datech o dříve přijatých zaměstnancích. ★☆☆
- Na jaře 2020 využíval systém „chytré karantény“ se souhlasem nakaženého data o poloze jeho mobilu a o platbách kartou, aby hygienici rychleji sestavili seznam kontaktů. Zhodnoť přínos a rizika pro soukromí a navrhní pravidla, za kterých je takové využití dat přijatelné. ★☆☆
- Otevřená data: Na Národním katalogu otevřených dat (data.gov.cz) najdi datovou sadu, ze které lze odpovědět na otázku o tvé obci nebo škole. Zapiš otázku, název sady, jak ověříš věrohodnost dat a zda sada neobsahuje osobní údaje. ★☆☆

16. Proč dotaz SELECT z H44 nad dvanácti řádky trvá okamžik, ale nad 10 miliardami řádků na jednom počítači by trval dlouho? Co s tím dělají systémy pro velká data? ★★☆☆

C. Problémy a propojení

17. Informatika: Program napodobuje princip MapReduce. Co vypíše? Která část by běžela souběžně na více serverech? ★★☆☆

```
casti = [{"data", "sit", "data"}, {"sit", "data", "model"}, {"data", "model"}]

def map_cast(slova):
    # běží souběžně na každém serveru
    vysledek = {}
    for s in slova:
        vysledek[s] = vysledek.get(s, 0) + 1
    return vysledek

mezivysledky = [map_cast(c) for c in casti]
celkem = {}
# sloučení dílčích výsledků
for m in mezivysledky:
    for slovo, pocet in m.items():
        celkem[slovo] = celkem.get(slovo, 0) + pocet
print(mezivysledky[1])
print(sorted(celkem.items()))
```

18. Matematika × soukromí: V obci žije 1 000 lidí. Předpokládej, že kombinace pohlaví, dne narození v roce a roku narození (80 ročníků) jsou rozloženy rovnoměrně. Kolik je různých kombinací? Jaká je pravděpodobnost, že konkrétní člověk nemá v obci „dvojníka“ se stejnou kombinací? Co to znamená pro „anonymní“ tabulku s těmito údaji? ★★☆☆
19. Odhad digitální stopy: Každý z 30 žáků skupiny denně pořídí 20 fotek po 3 MB, pošle 200 zpráv po 1 kB a jeho telefon každou minutu uloží polohu (100 B). Kolik dat vytvoří celá skupina za den? Která část je objemově největší a která nejcitlivější? ★★☆☆
20. Podklad k INF-10: Dokonči analýzu IS z H41 (úloha 20) hodnocením: a) bezpečnost – hrozby a opatření podle CIA; b) soukromí – jaká osobní data, k jakému účelu, jak dlouho a kdo k nim má přístup; c) dostupnost a přístupnost – co se stane při výpadku, náhradní postup, kdo má s ovládáním potíže; d) přínosy a nezamýšlené dopady na aspoň tři skupiny; e) tři konkrétní doporučení. ★★☆☆

Hotové úlohy k procvičení na internetu

- **Wikipedie – Velká data** – definice, charakteristiky (V), typy dat a technologie zpracování
https://cs.wikipedia.org/wiki/Velk%C3%A1_data
- **AI dětem – Velká data (big data)** – srozumitelné vysvětlení zdrojů a zpracování velkých dat, odkazy na výukové materiály
<https://aidetem.cz/portfolio/velka-data-big-data/>
- **Internetem bezpečně – Digitální stopa** – aktivní a pasivní stopa, metadata, rizika profilování a rady, jak stopu omezit
<https://www.internetembezpecne.cz/internetem-bezpecne/dobre-vedet/digitalni-stopu/>

★ základní · ★★ střední · ★★★ náročnější. Vyber si, které úlohy spočítáš; řešení ukládej do svého portfolia.

Výsledky ke kontrole

1. strukturovaná: a, c, e; nestrukturovaná: b, d, f (e-mail má strukturovanou hlavičku – je „polostrukturovaný“)
2. a) rychlost; b) rozmanitost; c) objem; d) věrohodnost; e) hodnota
3. $2\,500\text{ TB} = 2\,500\,000\text{ GB}$; $12,5\text{ MB/s}$; 250 filmů
4. $0,0005 \cdot 8\,760 \approx 4,4\text{ h}$
5. a) pseudonymizace – stále osobní údaj; b) anonymizace (agregace); c) nedostatečná – v malé obci lze člověka dohledat
6. aktivní: a, c; pasivní: b, d, e; f) stopa, kterou za tebe vytvořil někdo jiný (nemáš ji pod kontrolou)
7. vlak 245, bus 140, kolo 95; servery pracují souběžně, přenášejí se jen malé dílčí výsledky, při výpadku serveru se přepočítá jen jeho část
8. a) důvěrnost; b) integrita; c) dostupnost; d) dostupnost (i integrita); e) důvěrnost (soukromí)
9. 288 záznamů denně na telefon;
 $5 \cdot 10^6 \cdot 288 \cdot 300\text{ B} = 4,32 \cdot 10^{11}\text{ B} \approx 432\text{ GB}$ denně; $\approx 158\text{ TB}$ ročně
10. $t = \frac{8 \cdot 10^{12}}{10^8}\text{ s} = 80\,000\text{ s} \approx 22\text{ h}$; kurýr $\approx 1,5 \cdot 10^{10}\text{ b/s} \approx 15\text{ Gb/s}$ – obří objemy se proto často převážejí fyzicky
11. $0,005 \cdot 304 \cdot 24 \approx 36,5\text{ h}$; výpadek v den uzavírání známek nebo přijímaček je horší než v noci o prázdninách → plánovaná údržba mimo provoz
12. např. důvěrnost: únik citlivých zdravotních dat → šifrování, přístup jen oprávněných rolí, záznam přístupů; integrita: změna receptu → elektronický podpis lékaře; dostupnost: výpadek CÚER → záložní servery, náhradní postup; soukromí: lékový záznam vidí mnoho lidí → pacient může přístup omezit; přístupnost: senior bez mobilu → papírová průvodka
13. a) řidiči ušetří čas, obyvatelé ulic mají hluk a nebezpečí → omezení průjezdu, spolupráce města s navigací; b) zdraví lidé ušetří, nemocní a lidé bez náramku platí víc → dobrovolnost, zákaz znevýhodnění; c) rychlejší výběr, ale opakuje staré předsudky (např. vůči ženám) → kontrola zkreslení, rozhoduje člověk
14. přínos: rychlejší dohledání kontaktů, ochrana zdraví; rizika: citlivá data o pohybu a nákupech, možné zneužití či rozšíření účelu; pravidla: dobrovolný souhlas, jen nezbytná data, pevně daný účel a doba, smazání po skončení, kontrola nezávislým orgánem, transparentnost
15. otevřená úloha; hodnotí se jasná otázka, vhodná sada (poskytovatel, aktuálnost, formát CSV/JSON), kontrola věrohodnosti (zdroj, chybějící hodnoty, porovnání s jiným zdrojem) a úvaha o soukromí (agregovaná vs. osobní data)
16. bez indexu se musí projít všechny řádky – čas roste s objemem; řešení: indexy, rozdělení dat na mnoho strojů a paralelní výpočet (MapReduce), předem spočítané souhrny, práce se vzorkem
17. {'sit': 1, 'data': 1, 'model': 1} a [{'data': 4}, {'model': 2}, {'sit': 2}]; souběžně běží map_cast pro jednotlivé části, sloučení je rychlé
18. $2 \cdot 365 \cdot 80 = 58\,400$ kombinací;
 $P = \left(1 - \frac{1}{58\,400}\right)^{999} \approx 0,98$; asi 98 % lidí je jednoznačně určitelných – taková tabulka není anonymní
19. na žáka $\approx 60\text{ MB} + 0,2\text{ MB} + 0,14\text{ MB} \approx 60,3\text{ MB}$; skupina $\approx 1,8\text{ GB}$ denně; největší jsou fotky, nejcitlivější poloha – malý objem, ale prozradí bydliště, školu i zvyky
20. hodnotí se úplnost analýzy z H41, konkrétní hrozby a opatření ke každé složce CIA, úvaha o minimalizaci a době uchování dat, dostupnost i přístupnost, dopady na různé skupiny včetně nezamýšlených, zdůvodněná a proveditelná doporučení

Řešení krok za krokem

Úloha 18

1. Počet kombinací: 2 pohlaví · 365 dní · 80 ročníků, tedy $2 \cdot 365 \cdot 80 = 58\,400$.
2. Že jeden jiný člověk má jinou kombinaci než já, nastane s pravděpodobností $1 - \frac{1}{58\,400}$.
3. Ostatních lidí je 999 a jejich kombinace jsou nezávislé: $P = \left(1 - \frac{1}{58\,400}\right)^{999}$.
4. $P \approx 0,983 \approx 0,98$ – asi 98 % obyvatel nemá dvojníka.
5. Závěr: podle pohlaví a data narození jde skoro každého jednoznačně určit, taková tabulka není anonymní; údaje je třeba zhrubit (např. jen rok nebo desetiletí narození).

Úloha 20

1. Vezmi analýzu IS z H41 (účel, data a vazby, role, procesy, informační toky, technické řešení) a zkontroluj, že je úplná.
2. a) Ke každé složce CIA (důvěrnost, integrita, dostupnost) najdi aspoň jednu konkrétní hrozbu a opatření proti ní.
3. b) Sepiš osobní data: k jakému účelu se zpracovávají, jak dlouho se uchovávají a kdo k nim má přístup; navrhní, co by šlo nesbírat (minimalizace).
4. c) Popiš, co se stane při výpadku a jaký je náhradní postup; kdo může mít s ovládáním potíže (přístupnost) a jak mu pomoci.
5. d) Vyber aspoň tři skupiny lidí (i ty, kdo systém nepoužívají) a u každé uveď přínos a nezamýšlený dopad.
6. e) Napiš tři konkrétní, proveditelná doporučení a každé zdůvodni jednou větou.