

AI kriticky – jazykové modely a ověřování

3. a 4. ročník · červen
Týden 32 · hodina H63 · primárně oba ročníky

Výstupy ŠVP

INF-18 Identifikuji a řeším problémy a výzvy vznikající při práci s digitálními zařízeními a poradím s nimi druhým. (*Informatika 5, 3/1*)

INF-10 Rozpoznám informační toky v systémech; analyzuji a hodnotím informační systémy z různých hledisek; zvažuji i nepřímé a nezamýšlené dopady informačního systému na různé skupiny. (*Informatika 6, 3/2*)

INF-19b Při využívání digitálních technologií a sociálních sítí si umím chránit své soukromí a poskytovat o sobě pouze ty informace, které chci; v online světě se snažím minimalizovat svou digitální stopu, zejména tam, kde je to potenciálně nebezpečné. (*Informatika 4, 2/2 · z INF-19*)

Učivo: umělá inteligence – princip strojového učení; aplikace; limity, přínosy a rizika umělé inteligence; bezpečné digitální prostředí – digitální stopa

Lehké úlohy procvičí bigramový model, pravděpodobnost chyb a soukromí, střední teplotu modelu, ověřování výpočtů a zdrojů, těžké propojují jazykový model s pravděpodobností, testováním kódu a pravidly pro AI. Pojmy a vzorce máš v listu Must know. Vyber si, kolik úloh spočítáš; řešení si ukládej do svého portfolia.

Lehké ★☆☆

1. Z textu „já jím . já piju . ty jíš .“ urči $P(\text{jím}|\text{já})$ a $P(\text{jíš}|\text{ty})$.
2. Odpověď má 5 nezávislých tvrzení, každé je správné s pravděpodobností 0,9. Jaká je pravděpodobnost, že jsou správně všechna?
3. AI uvedla počet obyvatel Česka. Který zdroj je k ověření primární: (a) blog o cestování, (b) Český statistický úřad, (c) jiný chatbot, (d) diskusní fórum?
4. Předpokládej, že 1 token odpovídá asi 4 znakům anglického textu. Kolik tokenů má text o 2 000 znacích?
5. Které údaje jsou citlivé a do chatu s AI nepatří: (a) oblíbená barva, (b) diagnóza z lékařské zprávy, (c) náboženské vyznání, (d) školní rozvrh bez jmen, (e) číslo platební karty?
6. Doplň: V režimu Učení s vedením Gemini místo ... klade ..., rozkládá úlohu na ... a průběžně ověřuje, zda ...

Střední ★★☆☆

7. Model má pro tři možná další slova skóre $z = 2, 1, 0$. Převed' je na pravděpodobnosti vzorcem $p_i = \frac{e^{z_i/T}}{\sum e^{z_j/T}}$ pro teplotu $T = 1$ a $T = 2$. Co se se zvýšením teploty stane?
8. AI tvrdí: „Světlo ze Slunce k Zemi letí asi 8 sekund.“ Ověř výpočtem (vzdálenost $1,5 \cdot 10^{11}$ m, rychlost světla $3 \cdot 10^8$ m/s) a pojmenuj druh chyby.
9. Každé tvrzení je správné s pravděpodobností 0,99. Kolik nejvýš tvrzení smí odpověď mít, aby byla celá správně aspoň s pravděpodobností 0,9?
10. AI jako zdroj uvedla neznámý web s „přírodní léčbou“. Popiš laterální čtení: co a kde ověříš, než informaci použiješ.
11. Souřadnice ve fotce jsou uloženy na 4 desetinná místa stupně. S jakou přesností v metrech určí zeměpisnou šířku? ($1^\circ \approx 111,2$ km)
12. V trénovacích textech o „programátorovi“ jde v 800 z 1 000 případů o muže. Kolik z 50 vygenerovaných příběhů bude asi o muži, když model kopíruje četnosti? Navrhni dvě opatření.

Těžké ★★★

13. Bigramový model z textu „den je hezký . den je dlouhý . noc je dlouhá . den byl hezký .“ Spočítej $P(\text{je hezký} . |\text{den})$ a $P(\text{je hezký} . |\text{noc})$. Proč model hodnotí gramaticky chybnou větu „noc je hezký“ výš? Co dělají velké modely jinak?
14. AI odpoví na 50 otázek, každá odpověď je chybná s pravděpodobností 8 %. Ověřováním odhalíš 90 % chyb. Kolik chyb v průměru projde, když ověříš všechny odpovědi, a kolik, když ověříš jen polovinu?

15. AI napsala funkci na převod km/h na m/s. Napiš test, který chybu odhalí, a funkci oprav.

```
def na_ms(v):  
    return v * 3.6  
  
print(na_ms(36))
```

16. Navrhni pět pravidel pro používání AI v online škole (žáci i učitelé) tak, aby chránila soukromí, poctivost práce v portfolio a kvalitu učení. U každého uveď, jaký dopad nebo riziko řeší (INF-10).
17. Model má kontextové okno 128 000 tokenů. Kolik normostran (1 800 znaků) se do něj vejde, když 1 token odpovídá asi 4 znakům? Proč může model i tak „zapomenout“ začátek dlouhé konverzace?
18. Dvě různé AI se shodly na stejné (chybné) odpovědi. Kdyby chybovaly nezávisle, každá s pravděpodobností 10 %, jaká by byla pravděpodobnost, že obě chybují? Proč shoda dvou AI přesto není ověření?

Výsledky ke kontrole

1. $P(\text{jím|já}) = \frac{1}{2}$, $P(\text{jíš|ty}) = 1$
2. $0,9^5 \doteq 0,59$
3. (b) Český statistický úřad
4. asi 500 tokenů
5. (b), (c), (e); (a) a (d) nejsou citlivé
6. místo hotové odpovědi klade otázky, rozkládá úlohu na kroky a ověřuje, zda rozumíš
7. $T = 1$: 0,665; 0,245; 0,090; $T = 2$: 0,506; 0,307; 0,186 – pravděpodobnosti se vyrovnají, text je pestřejší, ale častěji vybere méně pravděpodobné (i chybné) slovo
8. $t = 500 \text{ s} \approx 8,3 \text{ min}$ – číslo sedí, ale záměna jednotek (sekundy $\times$ minuty)
9. $0,99^n \geq 0,9 \Rightarrow n \leq \frac{\ln 0,9}{\ln 0,99} \doteq 10,5$, tedy nejvýš 10 tvrzení
10. zjistit v jiných zdrojích, kdo web provozuje a proč; najít, co o něm píší důvěryhodné weby (fact-checking, odborné instituce); dohledat tvrzení v primárních zdrojích (Ministerstvo zdravotnictví, odborné společnosti, studie)
11. $0,0001^\circ \cdot 111,2 \text{ km} \doteq 11 \text{ m}$ – přesnost na budovu
12. asi 40; opatření: vyváženější data, výslovné zadání rozmanitosti, testování výstupů a jejich úprava, kritické čtení
13. $\frac{2}{3} \cdot \frac{1}{3} \cdot 1 = \frac{2}{9}$ a $1 \cdot \frac{1}{3} \cdot 1 = \frac{1}{3}$; bigram vidí jen předchozí slovo, neví, že podmětem je „noc“ (rod); velké modely počítají s dlouhým kontextem, a proto jsou plynulé – plynulost ale pořad není pravdivost
14. všechny: $50 \cdot 0,08 \cdot 0,1 = 0,4$; polovinu: $50 \cdot 0,08 \cdot (0,5 \cdot 0,1 + 0,5 \cdot 1) = 2,2$
15. vypíše 129.6; test assert `na_ms(36) == 10` skončí `AssertionError`; oprava `return v / 3.6` (u desetinných čísel porovnávat s tolerancí, např. `abs(na_ms(36) - 10) < 1e-9`)
16. např.: jen školní účet (ochrana dat); žádné osobní a citlivé údaje (soukromí); přiznat použití AI v portfoliu (poctivost); každé tvrzení ověřit v primárním zdroji (halucinace); k učení Učení s vedením, ne hotové odpovědi (porozumění); rovný přístup – alternativa pro žáky bez zařízení
17. $128\,000 \cdot 4 = 512\,000$ znaků, asi 284 normostran; starší text může z okna vypadnout a pozornost modelu se na dlouhém textu rozptýluje – důležité věci je lepší zopakovat
18. $0,1 \cdot 0,1 = 0,01$; chyby nejsou nezávislé – modely se učí na podobných datech a opakují stejné omyly, ověřuje se v nezávislém primárním zdroji