

AI kriticky – jazykové modely a ověřování

3. a 4. ročník · červen
Týden 32 · hodina H63 · primárně oba ročníky

Výstupy ŠVP

INF-18 Identifikuji a řeším problémy a výzvy vznikající při práci s digitálními zařízeními a poradím s nimi druhým. (Informatika 5, 3/1)

INF-10 Rozpoznám informační toky v systémech; analyzuji a hodnotím informační systémy z různých hledisek; zvažuji i nepřímé a nezamýšlené dopady informačního systému na různé skupiny. (Informatika 6, 3/2)

INF-19b Při využívání digitálních technologií a sociálních sítí si umím chránit své soukromí a poskytovat o sobě pouze ty informace, které chci; v online světě se snažím minimalizovat svou digitální stopu, zejména tam, kde je to potenciálně nebezpečné. (Informatika 4, 2/2 · z INF-19)

Učivo: umělá inteligence – princip strojového učení; aplikace; limity, přínosy a rizika umělé inteligence; bezpečné digitální prostředí – digitální stopa

Základní pojmy

Velký jazykový model (LLM) – Neuronová síť natrénovaná na obrovském množství textů; k zadání (promptu) generuje pravděpodobné pokračování textu. Gemini je příklad.

Token – Kousek textu (slovo, část slova, znak), se kterým model počítá; dlouhá česká slova se dělí na víc tokenů.

Předpověď dalšího tokenu – Model spočítá pravděpodobnost každého možného dalšího tokenu, jeden vybere, připojí ho a postup opakuje.

Trénovací data – Texty z webu, knih a kódu; model z nich převezme znalosti i chyby a předsudky; o dění po datu uzávěrky dat neví.

Dolaďování – Po předtrénování se model učí z příkladů a hodnocení lidí odpovídat užitečně a bezpečně; pravdivost tím zaručená není.

Kontextové okno – Kolik textu model „vidí“ najednou – zadání, dosavadní konverzace a vložené soubory.

Halucinace – Sebejistě podaná nepravda: vymyšlený fakt, číslo, citace, odkaz nebo chybný výpočet.

Zkreslení (bias) – Systematická nevyváženost výstupů převzatá z dat (pohlaví, jazyk, kultura, země).

Ověřování – Porovnání tvrzení s nezávislým primárním zdrojem; výpočty přepočítat, kód spustit, odkazy otevřít.

Laterální čtení – Důvěryhodnost zdroje zjišťuji v jiných zdrojích (kdo to píše, co o tom říkají ostatní), ne jen čtením jedné stránky.

Učení s vedením – Režim Gemini, který místo hotové odpovědi klade otázky, rozkládá úlohu na kroky a průběžně ověřuje, zda rozumíš.

Digitální stopa v AI – Zadání, nahrané soubory a historie konverzací; co vložím, opouští moje zařízení a ukládá se u poskytovatele.

Vzorce a vztahy

$$P(w_2|w_1) = \frac{N(w_1w_2)}{N(w_1)}$$

nejjednodušší (bigramový) jazykový model: pravděpodobnost dalšího slova z počtů dvojic v textu

$$P(w_1w_2w_3) = P(w_1) \cdot P(w_2|w_1) \cdot P(w_3|w_2)$$

pravděpodobnost věty jako součin

$$p_i = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}$$

převod skóre z_i na pravděpodobnosti; vyšší „teplota“ T = pestřejší, ale riskantnější text

$$P(\text{vše správně}) = p^n$$

n nezávislých tvrzení, každé správně s pravděpodobností p

Jak ověřit výstup AI

typ výstupu	typické riziko	jak ověřit
fakt, datum, číslo	halucinace, zastaralé údaje	primární zdroj (úřad, encyklopedie, učebnice), dva nezávislé zdroje
citace, odkaz, kniha	vymyšlený zdroj	otevřít odkaz, najít v katalogu knihovny nebo Google Scholar, stojí to tam?
výpočet	chyba v číslech, jednotkách, řádu	přepočítat (Python, kalkulačka), odhad řádu, kontrola jednotek
kód	logická chyba, neexistující funkce	spustit na testu se známým výsledkem (H31)
aktuality, místní informace	málo dat, uzávěrka dat	oficiální web, zpravodajství s datem
rada (zdraví, právo, peníze)	zobecnění, chybí kontext	odborník, oficiální zdroj

Poučky a postupy

- Model negeneruje pravdu, ale pravděpodobný text: plynulá a sebejistá odpověď ještě není správná odpověď.
- Čím vzácnější a konkrétnější informace (místní, nová, přesné číslo, citace), tím vyšší riziko halucinace.
- Postup ověření: rozlož odpověď na jednotlivá tvrzení → ke každému najdi primární zdroj → výpočty přepočítej → oprav a zapiš, co jsi ověřil(a).
- Zeptej se znovu a jinak, požádej o zdroje – ale i ty ověř, model je umí vymyslet.

5. Nevkládej osobní údaje své ani cizí (rodné číslo, adresa, zdraví, známky, hesla, fotky lidí); používej školní účet a řiď se pravidly školy pro AI.
6. Ve školním účtu Google Workspace for Education nejsou konverzace s Gemini podle Googlu čteny lidmi ani použity k trénování modelů – soukromí tím ale nekončí, co nevložíš, neunikne.
7. Učení s vedením: gemini.google.com → v poli pro zadání Přidat soubory → Další nástroje → Učení s vedením (v mobilní aplikaci Přidat soubory → Učení s vedením).
8. V portfoliu přiznej použití AI: k čemu, jaké zadání, co jsi ověřil(a) a opravil(a); AI není autor ani citovaný zdroj.

Pozor na

- Sebejistý tón není důkaz – model „neví, že neví“.
- Věrohodně vypadající citace (autor, časopis, ročník, DOI) může být celá vymyšlená.
- „Řekla to AI“ není zdroj: cituj primární zdroj, který jsi sám (sama) otevřel(a).
- Hodně desetinných míst neznamená přesnost – zkontroluj jednotky a řád výsledku.
- Smazané jméno nestačí: škola, třída a detaily příběhu člověka často prozradí.

Vzorový příklad

Odpověď AI obsahuje 8 nezávislých tvrzení, každé je správně s pravděpodobností 0,95. Jaká je pravděpodobnost, že je celá odpověď bez chyby? Kolik chybných tvrzení čekáš v průměru a od kolika tvrzení je chyba pravděpodobnější než bezchybnost?

1. Bez chyby: $0,95^8 \doteq 0,66$ – asi každá třetí taková odpověď obsahuje aspoň jednu chybu.
2. Průměrný počet chyb: $8 \cdot 0,05 = 0,4$ tvrzení na odpověď.
3. Hledáme n s $0,95^n < 0,5$: $n > \frac{\ln 0,5}{\ln 0,95} \doteq 13,5$, tedy od 14 tvrzení.
4. Závěr: čím delší a podrobnější odpověď, tím důležitější je ověřit každé tvrzení zvlášť.