

AI kriticky – jazykové modely a ověřování

Než začneš s kritickým používáním AI, zopakuj si pravděpodobnost, procenta, princip strojového učení, osobní údaje a digitální stopu, ověřování zdrojů a počítání výskytů v Pythonu.

1. Pravděpodobnost a násobení pravděpodobností SŠ

Kde to najdeš: Začátečníci H29 Kombinatorika a pravděpodobnost na začátek, 1.+2. H53 Pravděpodobnost

Pravděpodobnost jevů je podíl příznivých a všech stejně možných výsledků. U nezávislých jevů se pravděpodobnosti, že nastanou všechny, násobí. Pravděpodobnost opačného jevu je 1 minus pravděpodobnost jevu – tak se snadno spočítá, že nastane „aspoň jedna chyba“.

$$P(A) = \frac{m}{n} \text{ příznivé / všechny výsledky}$$

$$P(A \cap B) = P(A) \cdot P(B) \text{ nezávislé jevy}$$

$$P(\bar{A}) = 1 - P(A) \text{ opačný jev}$$

Příklad: Tři tvrzení jsou správně každé s pravděpodobností 0,95 (nezávisle). Jaká je pravděpodobnost, že je aspoň jedno chybné?

1. Všechna správně: $0,95^3 \doteq 0,857$.
2. Aspoň jedno chybné: $1 - 0,857 \doteq 0,143$.

Zkus sám:

1. Jaká je pravděpodobnost, že na dvou kostkách padnou dvě šestky?
2. Spočítej $0,9 \cdot 0,9 \cdot 0,9$.

2. Procenta a relativní četnost ZŠ

Kde to najdeš: Začátečníci H10 Procenta I: základ, část, počet procent, 1.+2. H55 Statistické charakteristiky

Relativní četnost je podíl počtu případů a všech případů; vynásobená stem dává procenta. Když AI odpoví správně na 18 z 20 otázek, je úspěšnost 90 %. Z procent zase spočítáš očekávaný počet: 2 % z 20 odpovědí je 0,4 odpovědi.

$$p = \frac{\text{část}}{\text{celek}} \cdot 100 \% \text{ počet procent}$$

Příklad: Z 25 odpovědí AI byly 3 chybné. Kolik procent je chybných a kolik chyb čekáš ve 200 odpovědích?

1. $\frac{3}{25} = 0,12 = 12 \%$.
2. $0,12 \cdot 200 = 24$ chyb.

Zkus sám:

1. Kolik procent je 7 chyb z 50 odpovědí?
2. Kolik jsou 2 % z 20?

3. Strojové učení a trénovací data SŠ

Kde to najdeš: 3.+4. H19 Umělá inteligence, 3.+4. H31 AI a modely – od dat k zákonitosti

Model strojového učení si parametry nastaví podle příkladů v trénovacích datech. Naučí se jejich vzory – i chyby a předsudky, které v nich jsou. O věcech, které v datech nebyly nebo byly vzácné, „neví“, a přesto může odpovědět sebejistě. Proto se model testuje na nových datech a jeho výstupy se ověřují.

Příklad: Rozpoznávač psů se učil jen na fotkách psů na trávě. Co se může stát s fotkou psa na sněhu?

1. Model se mohl naučit, že „pes = zelené pozadí“ (zkreslení dat).
2. Psa na sněhu nemusí poznat – data nebyla rozmanitá; pomůže doplnit různé fotky a test na nových datech.

Zkus sám:

1. Proč jazykový model neví o události z minulého týdne?
2. Proč model převeze předsudky?

4. Osobní údaje a digitální stopa **SS**

Kde to najdeš: 1.+2. H62 Digitální identita a stopa, 1.+2. H61 Bezpečnost zařízení a dat, 3.+4. H45 Velká data a hodnocení IS

Osobní údaj je jakákoli informace o konkrétním člověku (jméno, adresa, fotka, poloha); citlivé jsou např. údaje o zdraví, náboženství nebo biometrické údaje. Digitální stopa je vše, co o tobě na internetu zůstává – i to, co vložíš do chatu s AI. Kombinace detailů (škola, třída, věk) dokáže člověka určit i bez jména.

Příklad: Posuď zadání pro AI: „Jsem Petr ze 3. B na Gymnáziu v Brně, pomoz mi napsat omluvenku kvůli mé epilepsii.“

1. Jméno + třída + škola tě jednoznačně určí.
2. Epilepsie je citlivý údaj o zdraví.
3. Lepší zadání: „Pomoz mi napsat zdvořilou omluvenku kvůli zdravotním potížím.“

Zkus sám:

1. Je poloha ve fotce osobní údaj?
2. Jmenuj dva citlivé osobní údaje.

5. Ověřování informací a zdrojů **SS**

Kde to najdeš: 1.+2. H57 Interpretace a manipulace, 1.+2. H58 Statistika v médiích

Tvrzení ověřuješ v primárním zdroji (úřad, instituce, původní studie) a ideálně ve dvou nezávislých zdrojích. U neznámé stránky použij laterální čtení: otevři jiné weby a zjisti, kdo stránku provozuje a jak je důvěryhodná. U čísel sleduj jednotky, datum a zda graf nebo statistika nemanipuluje.

Příklad: AI tvrdí, že Česko má 12 milionů obyvatel. Jak to ověříš?

1. Primární zdroj: Český statistický úřad (czso.cz).
2. ČSÚ uvádí asi 10,9 milionu – tvrzení AI je chybné, oprav ho a uveď zdroj s datem.

Zkus sám:

1. Co je primární zdroj pro znění zákona?
2. Co uděláš, když AI uvede článek, který nejde najít?

6. Python: slovník a počítání výskytů **SS**

Kde to najdeš: 1.+2. H49 Cykly a seznamy, 1.+2. H52 Podprogramy

Slovník (dict) ukládá dvojice klíč → hodnota. Hodí se k počítání výskytů: pro každé slovo zvýšíš jeho počet o 1. Metoda get(klíč, 0) vrátí dosavadní počet, nebo 0, když klíč ještě neexistuje. Tak funguje i nejjednodušší jazykový model – počítá, co po čem následuje.

Příklad: Spočítej výskyty písmen ve slově „kokos“ pomocí slovníku.

1. $p = \{\}$ a pro každé písmeno $p[z] = p.get(z, 0) + 1$.
2. Výsledek: $\{'k': 2, 'o': 2, 's': 1\}$.

Zkus sám:

1. Jaký slovník vznikne počítáním písmen ve slově „ananas“?
2. Co vrátí $\{'a': 3\}.get('b', 0)$?

Kde se to doučit

- **Umíme informatiku – Základy umělé inteligence** – jazykové modely, halucinace a rizika stručně
<https://www.umimeinformatiku.cz/book/cviceni-zaklady-umele-inteligence>
- **Umíme informatiku – Osobní údaje** – procvičování: co je osobní a citlivý údaj
<https://www.umimeinformatiku.cz/cviceni-osobni-udaje>
- **Wikipedie – Halucinace (umělá inteligence)** – co jsou halucinace a proč vznikají
[https://cs.wikipedia.org/wiki/Halucinace_\(um%C4%9B%C3%A1_inteligence\)](https://cs.wikipedia.org/wiki/Halucinace_(um%C4%9B%C3%A1_inteligence))

Výsledky ke kontrole

- **1. Pravděpodobnost a násobení pravděpodobností:** 1) $\frac{1}{36}$; 2) 0,729
- **2. Procenta a relativní četnost:** 1) 14 %; 2) 0,4
- **3. Strojové učení a trénovací data:** 1) v trénovacích datech ještě nebyla (datum uzávěrky dat), pokud nemá přístup k vyhledávání; 2) jsou v trénovacích datech a model napodobuje jejich vzory
- **4. Osobní údaje a digitální stopa:** 1) ano – může prozradit, kde bydlíš; 2) např. zdravotní stav, náboženské vyznání (i biometrické údaje, sexuální orientace)
- **5. Ověřování informací a zdrojů:** 1) oficiální sbírka zákonů (např. e-Sbírka), ne článek o zákonu; 2) nepoužiju ho – nejspíš je vymyšlený (halucinace); tvrzení ověřím jinde
- **6. Python: slovník a počítání výskytů:** 1) {'a': 3, 'n': 2, 's': 1}; 2) 0