

AI kriticky – jazykové modely a ověřování

3. a 4. ročník · červen
Týden 32 · hodina H63 · primárně oba ročníky

Výstupy ŠVP

INF-18 Identifikuji a řeším problémy a výzvy vznikající při práci s digitálními zařízeními a poradím s nimi druhým. (*Informatika 5, 3/1*)

INF-10 Rozpoznám informační toky v systémech; analyzuji a hodnotím informační systémy z různých hledisek; zvažuji i nepřímé a nezamýšlené dopady informačního systému na různé skupiny. (*Informatika 6, 3/2*)

INF-19b Při využívání digitálních technologií a sociálních sítí si umím chránit své soukromí a poskytovat o sobě pouze ty informace, které chci; v online světě se snažím minimalizovat svou digitální stopu, zejména tam, kde je to potenciálně nebezpečné. (*Informatika 4, 2/2 · z INF-19*)

Učivo: umělá inteligence – princip strojového učení; aplikace; limity, přínosy a rizika umělé inteligence; bezpečné digitální prostředí – digitální stopa

Připomenutí

$$P(w_2|w_1) = \frac{N(w_1w_2)}{N(w_1)}$$

$$P(w_1w_2w_3) = P(w_1) \cdot P(w_2|w_1) \cdot P(w_3|w_2)$$

$$p_i = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}$$

$$P(\text{vše správně}) = p^n$$

Jak jazykový model tvoří text, proč halucinuje a je zkreslený, jak ověřovat fakta, citace a výpočty a jak chránit soukromí; Gemini v režimu Učení s vedením jako tutor. Podrobnosti najdeš v listu Must know.

A. Rozcvička

- Bigramový model z textu „ráno prší . ráno svítí slunce . večer prší . ráno prší .“ (tečka je také slovo). Spočítej $P(\text{prší}|\text{ráno})$ a $P(\text{svítí}|\text{ráno})$. Může model vytvořit větu „večer svítí slunce“? ★☆☆
- Model má po textu „Hlavní město Austrálie je“ tyto (vymyšlené) pravděpodobnosti dalšího slova: Sydney 0,40; Canberra 0,35; Melbourne 0,15; ostatní 0,10. Co napíše, když vždy vybírá nejpravděpodobnější slovo? Proč se to může stát? ★☆☆
- Předpokládej, že v angličtině připadá na 1 token asi 0,75 slova. Kolik tokenů má esej o 3 000 slovech? Proč vyjde v češtině na stejný počet slov tokenů víc? ★☆☆
- Je to halucinace? (a) Model uvede neexistující knihu i s ISBN. (b) Spočítá $17 \cdot 23 = 381$. (c) Řekne, že o události z minulého týdne nemá informace. (d) Tvrdí, že Praha má 3 miliony obyvatel. (e) Odmítne napsat cizí heslo. ★☆☆
- Co do chatu s AI patří a co ne? (a) zadání úlohy z fyziky; (b) tvoje rodné číslo; (c) fotka spolužáka z výletu; (d) tvůj text eseje bez jmen; (e) heslo ke školnímu účtu; (f) lékařská zpráva babičky; (g) naměřená data z pokusu. ★☆☆
- K výstupům AI přiřaď nejvhodnější ověření: (a) „Ohmův zákon objevil G. S. Ohm v roce 1827.“ (b) výpočet brzdné dráhy; (c) kód v Pythonu; (d) odkaz na článek s DOI; (e) „Škola má od září nové pravidlo...“. ★☆☆
- Odpověď obsahuje 12 nezávislých tvrzení, každé správné s pravděpodobností 0,97. Jaká je pravděpodobnost, že jsou všechna správná? Kolik chyb čekáš v průměru? ★★☆☆
- Jak v Gemini zapneš režim Učení s vedením? Čím se jeho odpověď liší od běžné a kdy ho použiješ? ★☆☆

B. Slovní úlohy

- Gemini napsal: „Ohřátí 1,5 l vody z 20 °C na 100 °C vyžaduje 50,2 kJ.“ Ověř výpočtem a napiš, jak se dá chyba poznat i bez přesného výpočtu. ★★☆☆
- AI k referátu uvedla zdroj: „Novák, J. (2019): Vliv AI na učení. Pedagogická revue 45(3), s. 112–130, DOI 10.1234/pr.2019.045.“ Popiš postup, jak ověříš, že zdroj existuje a opravdu obsahuje citované tvrzení. Co uděláš, když ho nenajdeš? ★★☆☆
- Požádáš AI o 20 krátkých příběhů o „inženýrovi“ a „zdravotníkoví“. V 18 příbězích je inženýr muž a v 17 je zdravotník žena. Odkud se to bere, na koho to může mít dopad a jak se tomu dá bránit? ★★☆☆
- Informační toky (INF-10): Vložíš úlohu do Gemini se školním účtem (od 18 let jako fotku, mladší žáci ji opíšíu textem – nahrávání souborů mají školní účty do 18 let vypnuté). Popiš, kudy fotka a zadání putují, kde zůstávají uložené, kdo o nich může rozhodovat a co můžeš nastavit ty. ★★☆☆
- Chceš po AI pomoc se slohovkou o své nemoci. Do zadání dáš jen křestní jméno, třídu a název školy. Je to anonymní? Jak zadání upraviš, aby o tobě prozradilo co nejméně (INF-19b)? ★★☆☆

14. AI odpovídá správně s pravděpodobností 0,9. Při ověřování odhalíš 80 % jejích chyb. Kolik procent odpovědí zůstane chybných i po tvé kontrole? Kolik takových chyb za týden „projde“, když od AI přijmeš 20 odpovědí? ★★☆☆
15. Úloha: vyřeš $x^2 - 5x + 6 = 0$. Popiš, jak by odpověděl Gemini v běžném režimu a jak v režimu Učení s vedením. Který režim použiješ před testem a který při kontrole domácí úlohy? ★☆☆
16. Nezamýšlené dopady (INF-10): Škola doporučí všem žákům Gemini jako tutora. Uveď aspoň dva přínosy a tři možné nezamýšlené dopady na různé skupiny (žáci, učitelé, rodiny, lidé s postižením) a jedno opatření ke každému dopadu. ★★☆☆

C. Problémy a propojení

17. Bigramový model v Pythonu: program spočítá dvojice slov v krátkém textu. Co vypíše? Urči pravděpodobnost, že model po slově „pes“ vytvoří větu „pes pije mléko“. Byla ta věta v textu? Co to říká o halucinacích? ★★☆☆

```
text = "kočka pije mléko . pes pije vodu . kočka spí . pes spí . kočka pije vodu ."
slova = text.split()
pocety = {}
for a, b in zip(slova, slova[1:]):
    pocety.setdefault(a, {})
    pocety[a][b] = pocety[a].get(b, 0) + 1
print(pocety["pije"])
print(pocety["pes"])
```

18. Rozbor chyby AI (INF-18): na dotaz „Auto jede 72 km/h a brzdí se zpomalením 4 m/s². Jaká je brzdná dráha?“ AI odpověděla: „ $s = \frac{v^2}{2a} = \frac{72^2}{2 \cdot 4} = 648$ m.“ Najdi chybu, oprav výpočet, ukaž, jak ji odhalíš odhad, a zapiš opravu tak, jak ji dáš do portfolia. ★★☆☆
19. Metadata fotky (INF-19b): Fotka úlohy, kterou chceš vložit do chatu, nese polohu 50° 05' 15" s. š., 14° 25' 20" v. d. Převeď souřadnice na desetinné stupně a spočítej, s jakou přesností v metrech určí místo, když jsou uvedeny na celé úhlové vteřiny (1° zeměpisné šířky $\approx 111,2$ km; délka se násobí $\cos \varphi$). Co uděláš před vložením fotky? ★★☆☆
20. Odhad: jazykový model byl trénován na $15 \cdot 10^{12}$ tokenech. Kdybys četl(a) 250 slov za minutu 8 hodin denně a na 1 token připadalo 0,75 slova, kolik let bys to četl(a)? Proč model i přes tolik dat halucinuje? ★★☆☆

Hotové úlohy k procvičení na internetu

- **Umíme informatiku – Základy umělé inteligence** – procvičování s okamžitou kontrolou: jazykové modely, halucinace, rizika
<https://www.umimeinformatiku.cz/cviceni-zaklady-umele-inteligence>
- **Umíme informatiku – Osobní údaje** – co je osobní a citlivý údaj a kdy ho nesdílet
<https://www.umimeinformatiku.cz/cviceni-osobni-udaje>
- **E-Bezpečí – Rizika spojená s generativní umělou inteligencí** – halucinace, zkreslení, dezinformace a soukromí s příklady
<https://ai.e-bezpecni.cz/rizika/>

★ základní · ★★ střední · ★★★ náročnější. Vyber si, které úlohy spočítáš; řešení ukládej do svého portfolia.

Výsledky ke kontrole

- $P(\text{prší}|\text{ráno}) = \frac{2}{3}$, $P(\text{svítí}|\text{ráno}) = \frac{1}{3}$; ne – po „večer“ v textu nikdy nebylo „svítí“, $P = 0$
- „Sydney“ – chyba, správně Canberra; v textech se Sydney vedle slova Austrálie objevuje častěji, model vybírá pravděpodobné, ne ověřené
- asi 4 000 tokenů; česká slova mají mnoho tvarů (koncovky) a v trénovacích datech je češtiny méně, tokenizér je dělí na víc kousků
- (a) ano – vymyšlený zdroj; (b) ano – chybný výpočet, správně 391; (c) ne – přiznaná mez trénovacích dat; (d) ano – Praha má asi 1,4 milionu; (e) ne
- patří: (a), (d), (g); nepatří: (b), (c) – cizí osobní údaj bez souhlasu, (e), (f) – citlivé údaje o zdraví
- (a) encyklopedie, učebnice, dva nezávislé zdroje; (b) přepočítat a zkontrolovat jednotky a řád; (c) spustit na testu se známým výsledkem; (d) otevřít doi.org a článek přechíst; (e) oficiální web nebo dokument školy
- $0,97^{12} \approx 0,69$; v průměru $12 \cdot 0,03 = 0,36$ chyby
- gemini.google.com → Přidat soubory → Další nástroje → Učení s vedením (v aplikaci Přidat soubory → Učení s vedením); klade otázky, vede po krocích, ověřuje porozumění – když se chceš látku naučit, ne jen získat výsledek
- $Q = 4\,180 \cdot 1,5 \cdot 80 = 501\,600 \text{ J} \approx 502 \text{ kJ}$ – Al se spletla desetkrát; odhad: asi 4 kJ na litr a kelvin, $4 \cdot 1,5 \cdot 80 \approx 500 \text{ kJ}$ (H32)
- zadat DOI na doi.org, hledat název v Google Scholar a v katalogu knihovny, najít web časopisu a jeho archiv, článek otevřít a najít tvrzení; když neexistuje – zdroj nepoužít, tvrzení ověřit jinde nebo vypustit, v portfoliu zapsat jako halucinaci
- zkreslení (bias) z trénovacích dat, která odrážejí stereotypy; dopad: posiluje stereotypy u dětí, zkresluje výběr (např. při třídění životopisů); obrana: rozmanitá data, testování výstupů, výslovné zadání, kritické čtení
- mobil → šifrované spojení přes internet → servery Googlu → model → odpověď zpět; uloženo v historii konverzací tvého účtu (a u Googlu podle jeho pravidel), přístup řídí správce školního účtu a pravidla školy; ty můžeš mazat konverzace a historii, fotit jen úlohu, nevkládat osobní údaje
- není – jméno + třída + škola + nemoc tě jednoznačně určí a jde o citlivý údaj o zdraví; upravit: bez jména a školy, nemoc popsat obecně nebo vymyšleně, požádat jen o strukturu a jazykové rady
- $0,1 \cdot 0,2 = 0,02 = 2\%$; v průměru $20 \cdot 0,02 = 0,4$ chyby týdně (bez kontroly 2 chyby)
- běžný režim: hned řešení $x_1 = 2$, $x_2 = 3$ s postupem; Učení s vedením: ptá se, co už víš (diskriminant, rozklad), nechá tě dělat kroky a kontroluje je; učení a příprava → Učení s vedením, kontrola výsledku → běžný režim nebo dosazení
- přínosy: vysvětlení kdykoli, přizpůsobení tempu, pomoc žákům s dyslexií (předčítání, zjednodušení); dopady: opisování bez porozumění → úlohy s vlastními daty a ústní obhajoba; nerovný přístup (slabý internet, starý mobil) → školní zařízení, offline materiály; chyby a zkreslení → povinné ověřování; menší kontakt s učitelem → konzultace
- {'mléko': 1, 'vodu': 2} a {'pije': 1, 'spí': 1}; $P = \frac{1}{2} \cdot \frac{1}{3} \cdot 1 = \frac{1}{6}$; věta v textu nebyla – model skládá nové, gramaticky správné věty z naučených vzorů, které nemusí být pravdivé
- rychlost nebyla převedena na m/s: $v = 20 \text{ m/s}$, $s = \frac{400}{8} = 50 \text{ m}$; odhad: 648 m je přes půl kilometru, brzdná dráha auta z městské rychlosti jsou desítky metrů
- $\varphi \approx 50,0875^\circ$, $\lambda \approx 14,4222^\circ$; 1" šířky $\approx 31 \text{ m}$, 1" délky $\approx 20 \text{ m}$ – určí konkrétní dům; před vložením vypnout polohu ve fotoaparátu nebo metadata odstranit, fotit jen úlohu (bez lidí, adres)
- $1,125 \cdot 10^{13}$ slov, denně 120 000 slov → asi $9,4 \cdot 10^7$ dní $\approx 260\,000$ let; model si nepamatuje texty doslova, ukládá statistické vzory; vzácné informace viděl málokdy a mezi daty jsou i chyby

Řešení krok za krokem

Úloha 17

- Program projde všechny dvojice sousedních slov a spočítá, kolikrát po slově a následuje slovo b .
- Po „pije“ následuje 1× „mléko“ a 2× „vodu“; po „pes“ 1× „pije“ a 1× „spí“.
- $P(\text{pije}|\text{pes}) = \frac{1}{2}$, $P(\text{mléko}|\text{pije}) = \frac{1}{3}$, $P(.|\text{mléko}) = 1$.
- $P(\text{pije mléko} .|\text{pes}) = \frac{1}{2} \cdot \frac{1}{3} \cdot 1 = \frac{1}{6}$.
- Věta „pes pije mléko“ v textu není: model kombinuje vzory, tvoří věrohodné nové věty – stejný mechanismus u velkých modelů vede k halucinacím.

Úloha 18

1. Vzorec $s = \frac{v^2}{2a}$ je správný (rovnoměrně zpomalený pohyb do zastavení, H15 v 1.+2. ročníku).
2. Chyba: dosazena rychlost v km/h a zrychlení v m/s² – nesourodé jednotky.
3. Převod: $72 \text{ km/h} = \frac{72}{3,6} = 20 \text{ m/s}$.
4. $s = \frac{20^2}{2 \cdot 4} = \frac{400}{8} = 50 \text{ m}$.
5. Odhad řádu: 648 m by bylo víc než 6 fotbalových hřišť – nesmysl, který se pozná i bez výpočtu.
6. Do portfolia: zadání, odpověď AI, typ chyby (jednotky), oprava, jak jsem ji našel (kontrola jednotek, odhad).

Úloha 19

1. $\varphi = 50 + \frac{5}{60} + \frac{15}{3\,600} \doteq 50,0875^\circ$; $\lambda = 14 + \frac{25}{60} + \frac{20}{3\,600} \doteq 14,4222^\circ$.
2. 1" šířky: $\frac{111,2 \text{ km}}{3\,600} \doteq 30,9 \text{ m}$.
3. 1" délky: $30,9 \text{ m} \cdot \cos 50,09^\circ \doteq 30,9 \cdot 0,642 \doteq 19,8 \text{ m}$.
4. Místo je určeno s přesností asi 20–30 m – na konkrétní dům; fotka tak může prozradit, kde bydlíš (viz karta K32).
5. Ochrana: vypnout ukládání polohy ve fotoaparátu, odstranit metadata, vložit jen výřez úlohy.

Úloha 20

1. Slovo: $15 \cdot 10^{12} \cdot 0,75 = 1,125 \cdot 10^{13}$.
2. Za den: $250 \cdot 60 \cdot 8 = 120\,000$ slov.
3. Dní: $\frac{1,125 \cdot 10^{13}}{1,2 \cdot 10^5} \doteq 9,4 \cdot 10^7$, tj. asi $2,6 \cdot 10^5$ let.