

Ověřuj a přemýšlej

Halucinace, jak ověřovat (druhý zdroj, výpočet, zkouška), kritické myšlení, deepfake a manipulace

Všechny kurzy · pro žáky

Gemini – stejně jako každý jiný chatbot – je jazykový model. Skládá nejpravděpodobnější pokračování textu. Většinou to vyjde, ale někdy vytvoří odpověď, která zní skvěle a přitom je nepravdivá. Tomu se říká halucinace. Google sám upozorňuje, že Gemini je AI a může dělat chyby, a to i v tom, co tvrdí o lidech. Tvoje práce je nevěřit slepě a ověřovat.

Jak vypadá halucinace

- Vymyšlený zdroj: kniha, článek nebo odkaz, který neexistuje – nebo existuje, ale píše něco jiného.
- Vymyšlené číslo: tabulková hodnota, letopočet nebo statistika bez zdroje.
- Chybný výpočet s přesvědčivým postupem, kde je chyba schovaná v jednom mezikroku.
- Zaměněné pojmy: rychlost a zrychlení, teplo a teplota, bit a bajt. Jinak správný text s jednou chybnou větou.
- Neaktuální informace: pravidla maturity, termíny, ceny, verze programů.
- Přílišná ochota souhlasit: když se zeptáš sugestivně, AI ti často dá za pravdu.

Pět způsobů, jak ověřit odpověď

Způsob	Jak na to	Kdy
Výpočet a zkouška	spočítej sám nebo sama, dosad' výsledek, zkus jinou metodu	matematika, fyzika
Odhad a rozumnost	řád, jednotky, znaménko, hranice (pravděpodobnost od 0 do 1)	každý číselný výsledek
Druhý zdroj	Must know, učebnice, web instituce nebo univerzity, Cermat	fakta, definice, vzorce, konstanty
Spuštění a test	kód spusť, zkus okrajové vstupy, porovnej s očekávaným výstupem	informatika
Otevři zdroj	tlačítko Zdroje u odpovědi – přečti si, co zdroj opravdu píše	fakta z webu

Tlačítko Zdroje

Když Gemini k odpovědi uvede odkazy, uvidíš pod odpovědí nebo v ní tlačítko Zdroje a vpravo se otevře panel s odkazy. Když tlačítko chybí, Gemini k odpovědi žádné odkazy neuvedlo – o to pečlivěji ověřuj. Odkaz vždy otevři: i skutečný zdroj může říkat něco jiného, než AI tvrdí.

Chtěj, ať se AI sama kontroluje

Tvoji odpověď si budu ověřovat. Napiš mi, kterými částmi si jsi jistý a kterými ne, a u každého čísla uveď, odkud je. Když zdroj nemáš, napiš to otevřeně.

Test přikyvování

Myslím si, že 0,999... (devítky pořád dál) je menší než 1. Mám pravdu? Neuhýbej – když se mýlím, řekni to a vysvětli proč. Pak se mě zeptej, jestli to umím zdůvodnit sám.

Proč ten test

Správná odpověď je, že číslo 0,999... s nekonečně mnoha devítkami se rovná 1. Když ti AI přikývne, vidíš, že umí souhlasit i s chybou. Proto se neptej „Že je to tak?“, ale „Je to tak, nebo ne? Zdůvodni to.“

Kritické myšlení – otázky, které si polož

- Kdo to tvrdí a odkud to ví? Dá se to ověřit jinde?
- Není odpověď až moc jistá nebo až moc obecná? Chybí čísla, jednotky, zdroj?
- Neříká AI jen to, co chci slyšet? Zkus se zeptat opačně: „Proč by to NEBYLA pravda?“
- U grafu nebo statistiky: jsou popsány osy, jednotky a zdroj dat? Nezačíná osa jinde než u nuly, aby rozdíl vypadal větší? (STEM 1.+2. – Interpretace a manipulace, Statistika v médiích)
- Rozumím tomu tak, že to umím vysvětlit bez AI? Jestli ne, ještě to neumím.

Deepfake a manipulace

Deepfake je obrázek, video nebo zvuk vytvořený či upravený AI tak, aby vypadal jako skutečný – třeba známá osobnost „doporučuje“ investici nebo hlas někoho blízkého naléhavě chce peníze. Staré rady typu „poznáš to podle rozmazaných zubů“ už moc neplatí: dnešní nástroje takové chyby dělat nemusí. Ověřuj proto hlavně obsah a původ, ne vzhled.

- Kdo to zveřejnil a kde je originál? Píší o tom důvěryhodná média nebo oficiální web dané osoby či instituce?

- Varovné signály: naléhání („hned“, „jen dnes“), silné emoce (strach, vztek, nadšení), žádost o peníze, heslo, kód z SMS nebo instalaci aplikace.
- Když ti volá nebo píše „známý“ s neobvyklou prosbou, ověř to jinou cestou – zavolej mu na číslo, které znáš.
- Obrázek zkus dohledat zpětným vyhledáváním obrázků – starší původní verze často prozradí podvrh.
- Gemini umí zkontrolovat, jestli obrázek, video nebo zvuk nese neviditelný vodoznak SynthID. Poznává ale jen obsah z AI nástrojů Googlu: když vodoznak nenajde, neznamená to, že je obsah pravý. Kontrola vyžaduje nahrání souboru, takže se školním účtem pod 18 let nemusí být dostupná.
- Nesdílej, co nemáš ověřené. A nikdy nevytvářej deepfake skutečného člověka, ani „jako vtip“ – může to být šikana, poškození cizích práv i trestný čin.

Manipulace pomocí AI

- AI dokáže rychle psát přesvědčivé texty s vymyšlenými „fakty“: falešné recenze, zprávy, citáty známých lidí.
- Stejná otázka položená jinak dá jinou odpověď. Sugestivní otázka („Proč je X špatně?“) vede k jednostranné odpovědi.
- Chceš vyvážený pohled? Zeptej se: „Uveď nejsilnější argumenty pro i proti a ke každému zdroj, který si ověřím.“

Kontrola před použitím odpovědi

1. Rozumím odpovědi a umím ji říct vlastními slovy?
2. Ověřil/a jsem čísla výpočtem, zkouškou nebo odhadem?
3. Mám pro fakta druhý, důvěryhodný zdroj?
4. Sedí jednotky a řád výsledku?
5. Víím, co v odpovědi je od AI a co je moje – a umím to v portfoliu popsat (návod 07)?

Zdroje a odkazy

- **Nápověda Google – Zobrazení souvisejících zdrojů z aplikací s Gemini** – tlačítko Zdroje pod odpovědí, citace webu a kódu včetně licence open source
<https://support.google.com/gemini/answer/14143489?hl=cs>
- **Nápověda Google – Ověření obrázků, videí a zvuku vygenerovaných AI** – ověření vodoznaku SynthID v Gemini a co výsledek (ne)znamená
<https://support.google.com/gemini/answer/16722517?hl=cs>
- **ONLIFE (KISK FF MU) – Manipulace s grafy** – jak grafy a čísla klamou – kritické čtení informací
<https://kisk.phil.muni.cz/onlife/temata/hodnoceni-informaci/manipulace-s-grafy>
- **Umíme informatiku – Techniky manipulace a argumentační fauly** – procvičení, jak poznat manipulativní argument
<https://www.umimeinformatiku.cz/cviceni-techniky-manipulace-fauly>